Juízes de segurança de LLM em português: medindo o deslocamento de língua

Cristhian Kapelinski

1 Problema

Zheng et al. [1] sistematizaram o uso de modelos de linguagem como juízes automáticos e mediram concordância acima de 80% com avaliadores humanos em tarefas de propósito geral, patamar igual ao da concordância entre os próprios humanos. Desde então a prática se firmou como padrão de avaliação em escala [2, 5]. Em segurança, são esses juízes que sustentam o benchmarking, o red teaming automatizado e os guardrails em produção [3], decidindo se uma resposta gerada é nociva. Ao ler que um ataque obteve certa taxa de sucesso, quem produziu esse número não foi uma pessoa, foi esse classificador. O juiz é o instrumento de medida do campo inteiro, e um instrumento descalibrado não produz erro aleatório, produz conclusão errada com aparência de rigor.

Dois trabalhos recentes mostraram que esses juízes são frágeis. Eiras et al. [3] verificaram, sobre o conjunto de comparação de juízes do JailbreakBench [4], que reescrever a mesma resposta em tom narrativo, sem alterar o conteúdo, eleva de 0,12 para 0,36 a taxa de falso negativo do juiz HarmBench, ou seja, triplica a fração de respostas nocivas que ele libera como seguras. No mesmo estudo, o WildGuard, melhor juiz na condição de referência, deixa de detectar qualquer resposta nociva quando o texto é envolvido por conteúdo benigno. Schwinn et al. [5], a partir de 6.642 rótulos atribuídos por pessoas, concluíram que essa concordância alta não sobrevive ao cenário adversarial: sob os deslocamentos de distribuição típicos de red teaming o desempenho dos juízes cai para perto do acaso. Em um dos cortes reportados, a área sob a curva ROC do juiz JailJudge sobre respostas do modelo Llama-3.1-8B fica entre 0,48 e 0,64, sendo 0,50 o valor de quem responde por sorteio.

Schwinn et al. [5] nomeiam três deslocamentos que quebram o juiz, resumidos na Figura 1: o do ataque aplicado, o do modelo avaliado e o da categoria semântica do conteúdo. Nenhum dos dois trabalhos considera o deslocamento mais barato e mais comum fora do mundo anglófono, que é a língua: todos os experimentos são em inglês. O trabalho mais próximo em português mede disparidade de alinhamento entre grupos demográficos [6], mas ali o juiz é o instrumento, não o objeto medido. A Tabela 1 resume o estado: mede-se quanto cada juiz degrada em inglês e, até onde pudemos verificar, nada foi publicado sobre português.

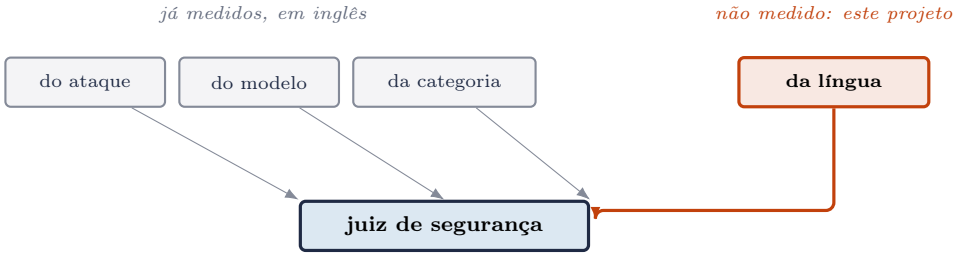


Figura 1: Os deslocamentos de distribuição que degradam um juiz de segurança. Os três à esquerda foram medidos em inglês por Schwinn et al. [5]; o quarto é o objeto desta proposta.

Tabela 1: Taxa de falso negativo (FN) dos juízes de segurança, isto é, a fração de respostas nocivas classificadas como seguras. Valores em inglês reportados por Eiras et al. [3]; a última coluna é o que este projeto mede.

Juiz de segurança	FN base (EN)	FN sob reescrita (EN)	FN em PT-BR
HarmBench (LLaMA-2 13B)	0,12	0,36	?
ShieldGemma 9B	0,50	0,70	?
WildGuard	0,02	0,12	?
LLaMA Guard 3 8B	0,04	0,02	?

2 Proposta

É essa lacuna que o projeto ocupa. A proposta é tratar a língua como um quarto deslocamento de distribuição, ao lado dos três já descritos, e medir quanto os juízes de segurança degradam quando o conteúdo julgado está em português brasileiro.

O alvo escolhido torna a pergunta incisiva. Schwinn et al. [5] publicaram o ReliableBench, um subconjunto de 41 comportamentos escolhidos justamente por serem confiáveis de julgar, e nos quais a acurácia média dos juízes sobe de 57% para 70%. Esse subconjunto é o remédio que os próprios autores propõem contra a falta de confiabilidade que mediram. Daí a pergunta central: o ReliableBench continua confiável em português? Se a acurácia cair ao traduzir o conteúdo, a confiabilidade que ele oferece é propriedade da língua inglesa e não do comportamento avaliado, e o remédio proposto pela literatura não atravessa a fronteira linguística. Se não cair, obtém-se evidência de estabilidade desses juízes em português, o que, até onde pudemos verificar, ainda não existe. Nos dois casos há resultado, o que remove o risco de o projeto terminar sem conclusão.

A inteligência artificial entra em três papéis: como objeto de estudo, que são os juízes auditados; como ferramenta, na tradução das amostras, revisada por falante nativo; e como apoio de ideação nesta proposta. Vale delimitar o que este trabalho não é: ele não propõe um juiz novo, não ataca modelo nenhum e não mede a segurança de assistentes em produção. Ele afere o instrumento, não o objeto que o instrumento aponta.

3 Execução

Responder a essa pergunta exige isolar a língua de todo o resto, e é isso que a Figura 2 organiza. O desenho é uma comparação pareada: o mesmo conteúdo, com o mesmo rótulo humano, passa pelos mesmos juízes em duas línguas, de modo que a diferença entre as métricas não pode ser atribuída a outra coisa senão à língua.

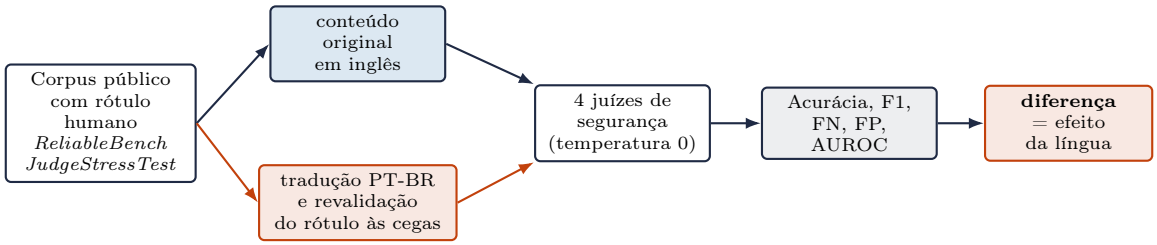


Figura 2: Desenho pareado. O rótulo humano já vem do corpus público; o trabalho é traduzir, revalidar às cegas e medir a diferença.

Dados. Não há rotulação do zero. O ReliableBench e o JudgeStressTest, este último com 971 amostras difíceis de julgar, são públicos e já acompanham rótulos atribuídos por pessoas.[1] O trabalho é traduzir esse material e validar a preservação do rótulo pelo protocolo de Eiras et al. [3]: re-anotação às cegas de uma amostra, sem acesso ao rótulo original, confirmando que a tradução não alterou o caráter nocivo do conteúdo. Rotular passa a ser verificar, o que cabe no semestre.

Ameaça à validade. Traduzir não é neutro: Brito et al. [6] descartaram a tradução automática em corpus bilíngue porque a carga ofensiva depende da cultura. É o que a revalidação às cegas testa, e quantos itens caem nessa etapa é, por si só, um resultado a reportar.

Juízes e métricas. Sobre esse material corre a medição propriamente dita. São os juízes abertos usados nos dois estudos de referência, executados localmente com temperatura zero para que o resultado seja reproduzível. As métricas são as mesmas da literatura, o que permite comparação direta com os números já publicados em inglês, mais o escore de concordância entre juízes de Schwinn et al. [5], que mede consenso sem depender de rótulo humano e serve para detectar o caso em que todos os juízes passam a errar juntos em português.

Recursos e etapas. Nada disso exige infraestrutura incomum: Python, a biblioteca Transformers e uma placa gráfica com memória para o maior juiz, de 13 bilhões de parâmetros, sem custo de interface paga e sem dados sensíveis. As etapas seguem a ordem do diagrama: reproduzir o resultado publicado em inglês, traduzir e validar o conjunto em português, executar os juízes e analisar.

4 Resultado esperado

Ao fim do semestre existirão duas coisas que hoje, até onde pudemos verificar, não existem: um conjunto de avaliação de segurança em português com rótulo humano validado, útil a qualquer trabalho posterior na língua, e a medida de quanto cada juiz erra sobre ele. Essa medida responde se os números publicados sobre modelos em português descrevem o modelo avaliado ou o instrumento que o avalia. Um resultado nulo é igualmente informativo, porque hoje a confiabilidade em português é suposta e não medida.

[1] Schwinn et al., LLMJudgeReliability, 2026

Referências

[1] Zheng, L., Chiang, W.-L., Sheng, Y., and others (2023). Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena. *NeurIPS 2023, Datasets and Benchmarks*. arXiv:2306.05685.

[2] Gu, J., Jiang, X., Shi, Z., and others (2024). A Survey on LLM-as-a-Judge. arXiv:2411.15594.

[3] Eiras, F., Zemour, E., Lin, E., and Mugunthan, V. (2025). Know Thy Judge: On the Robustness Meta-Evaluation of LLM Safety Judges. *ICBINB Workshop @ ICLR 2025*. arXiv:2503.04474.

[4] Chao, P., Debenedetti, E., Robey, A., and others (2024). JailbreakBench: An Open Robustness Benchmark for Jailbreaking Large Language Models. *NeurIPS 2024, Datasets and Benchmarks*. arXiv:2404.01318.

[5] Schwinn, L., Ladenburger, M., Beyer, T., Mofakhami, M., Gidel, G., and Günnemann, S. (2026). A Coin Flip for Safety: LLM Judges Fail to Reliably Measure Adversarial Robustness. arXiv:2603.06594.

[6] Brito, I. A., Rios, W. S. R., Dollis, J. S., Silva, D. F. C., and Galvão Filho, A. R. (2026). Safety Is Not Universal: The Selective Safety Trap in LLM Alignment. arXiv:2601.04389.

[7] Zhang, Q., Xiong, Z., and Mao, Z. M. (2024). LLM Safeguard is a Double-Edged Sword: Exploiting False Positives for Denial-of-Service Attacks. arXiv:2410.02916.

A Uso da IA na elaboração desta proposta

Esta proposta nasceu de uma conversa de ideação com o Claude, em várias rodadas de crítica.

O prompt inicial pedia ideias de projeto de IA adversarial executáveis em um semestre. A primeira rodada veio enviesada: o modelo leu anotações de estudo antigas minhas e montou as sugestões em torno de lacunas de conhecimento que já não existiam. Descartei o enquadramento inteiro e exigi outro critério, qual pergunta tem resposta que não se consegue prever de antemão. Ele não depende do que eu já sei, e sozinho eliminou três das seis ideias iniciais, todas de resultado óbvio para quem conhece a área: ataque multiturno contra filtro de turno único, perturbação por homóglifos e envenenamento de recuperação aumentada. Outras duas caíram por viabilidade: otimizar sufixos adversariais por gradiente entre línguas custa computação demais, e envenenar o laço de adaptação de um limiar dinâmico exigiria construir a defesa antes de atacá-la, e a ideia mais geral de explorar falsos positivos para negar serviço já está publicada [7].

O passo decisivo foi exigir verificação na literatura antes de aceitar a ideia, e a busca revelou que a ideia aprovada já existia, bem executada, em inglês. Em vez de abandonar o tema, exigi a checagem dos dois artigos contra a fonte primária e usei o resultado para reduzir o escopo: sobrou o eixo que nenhum cobre, a língua, e um alvo concreto, o ReliableBench. Também contestei um dado de anotação que o modelo havia repetido a partir de resultados de busca: conferido no artigo, o dado se sustentava. A mesma checagem revelou uma ameaça à validade que nenhum resumo mostrava, tratada na Seção 3.

Os principais prompts foram: (i) “quero ideias de projeto de IA adversarial que me ajudem a aprender mais sobre a área”; (ii) “essas anotações estão desatualizadas, a maioria eu já sei, tente não ter viés”; (iii) “isso se encaixa no enunciado da disciplina?”; (iv) “pesquise se não tem algo exatamente assim na literatura”; e (v) “e fazer algo relacionado ao português em juiz?”.