Juízes de segurança de LLM em português: medindo o deslocamento de língua

Cristhian Kapelinski
Atividade 2: investigação e aprofundamento técnico

1 Problema e aplicação

Medir se um modelo de linguagem produziu conteúdo nocivo é feito hoje por um *juiz*, que é outro modelo treinado para classificar a resposta como segura ou nociva. Todo número de segurança publicado depende desse classificador. O problema é que os juízes disponíveis foram construídos e validados em inglês, e, até onde pudemos verificar, não há medição do que acontece com eles em português. Afetados: quem avalia assistentes conversacionais em português, seja em pesquisa ou em empresa, e acaba reportando um número cuja margem de erro desconhece.

Tarefa de IA. Classificação binária. A **entrada** é um par (prompt, resposta) em português; a **saída** é o rótulo nocivo ou seguro. O sistema a construir não é o classificador, e sim o arcabouço que o *afere*, como mostra a Figura 1.

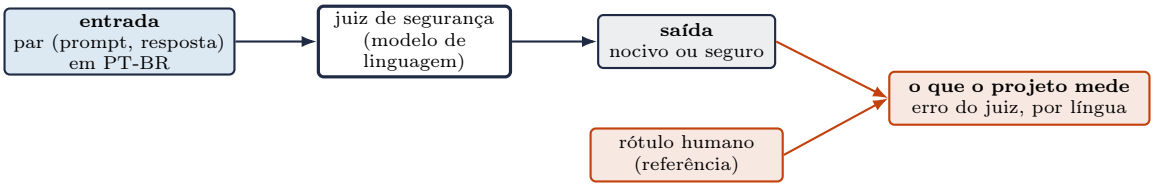


Figura 1: A tarefa de IA é a classificação feita pelo juiz. O projeto não constrói o juiz: mede a distância entre a saída dele e o rótulo humano, em cada língua.

Por que IA, e não uma abordagem tradicional. A alternativa tradicional é o casamento de palavras-chave, e ela já foi medida. No JailbreakBench, esse juiz por regras concorda com anotadores humanos em 56,0% dos casos [2]. Sortear daria perto disso. Julgar exige entender recusa educada, ironia e cumprimento parcial, o que uma lista de termos não captura. Por isso o método baseado em regras entra aqui como piso de comparação, não como solução.

2 Dados

Não é necessário coletar nem anotar de zero, o que é decisivo para o prazo. Três conjuntos públicos já trazem rótulo humano e cobrem o que o projeto precisa, como resume a Tabela 1.

Tabela 1: Conjuntos de dados. Todos públicos e com rótulo humano de origem.

Conjunto	Tamanho	Rótulo	Língua	Papel no projeto
ReliableBench [4]	41 comport.	humano	EN	conjunto principal
JudgeStressTest [4]	971 amostras	humano	EN	casos difíceis
Comparação de juízes [2]	300 pares	3 anotadores	EN	baseline de referência
Versão PT-BR (a produzir)	**100–300 pares**	**revalidado**	**PT-BR**	**contribuição**

Qualidade, viés e risco. O risco central é a tradução. Brito et al. [5] descartaram tradução automática ao montar um corpus bilíngue porque a carga ofensiva depende da cultura e se perde no caminho. A mitigação é a revalidação às cegas: reanotar a versão traduzida sem ver o rótulo original e descartar o item que divergir. A taxa de descarte é resultado a reportar, não um detalhe de implementação. Há ainda desbalanceamento conhecido, tratado por subamostragem equilibrada como em [3], e risco de contaminação, já que conjuntos públicos podem ter entrado no treino dos juízes. Sobre privacidade não há exposição: o conteúdo é sintético e público, sem dado pessoal.

3 Inteligência artificial e trabalhos relacionados

Técnica. Nenhum treinamento é necessário: os juízes são usados em inferência, com temperatura zero para reprodutibilidade. Isso mantém o projeto pequeno e a comparação honesta, porque treinar mudaria o instrumento que se quer medir. Serão comparados quatro juízes abertos usados na literatura de referência, LlamaGuard-3 8B, o classificador HarmBench de 13B, AegisGuard e JailJudge, mais o piso baseado em regras. **Requisitos:** o maior modelo tem 13 bilhões de parâmetros, cerca de 26 GB em meia precisão, ou perto de 8 GB com quantização de 4

Tabela 2: Posicionamento. A coluna central indica se o juiz é o objeto medido ou apenas o instrumento usado.

Trabalho	**Abordagem**	**Juiz é o objeto?**	**Limitação a explorar**
Zheng et al. [1]	concordância juiz-humano em tarefas gerais	sim	não trata segurança nem outra língua
Chao et al. [2]	escolhe o melhor juiz entre seis	sim	escolha estática, sem deslocamento
Eiras et al. [3]	altera estilo e saída, mede falso negativo	sim	só inglês, 100 exemplos
Schwinn et al. [4]	três deslocamentos, 6.642 rótulos	sim	língua não é um dos deslocamentos
Brito et al. [5]	disparidade demográfica, corpus EN e PT	não	usa o juiz sem aferi-lo em PT
Este trabalho	**língua como quarto deslocamento**	**sim**	—

bits; o volume total fica na ordem de milhares de inferências, viável em horas em uma GPU com memória suficiente para o maior juiz.

A Tabela 2 situa o projeto entre esses trabalhos. A diferença em relação a todos eles é de eixo, não de método: o protocolo é o mesmo já publicado, aplicado a uma variável que nenhum deles varia. Isso é deliberado, pois reusar protocolo validado reduz risco e torna os resultados diretamente comparáveis aos números em inglês.

4 Desenvolvimento e avaliação

Tabela 3: Riscos técnicos e alternativas.

Risco	**Alternativa**
Tradução altera a nocividade e o descarte fica alto	restringir a comportamentos sem carga cultural; reportar a taxa de descarte como achado
GPU insuficiente para o juiz de 13B	quantização de 4 bits, ou usar somente juízes de até 8B
Juiz se recusa a julgar, como relatado em [2]	adotar o prompt específico do JailbreakBench ou trocar o modelo
Conjunto público já usado no treino do juiz	declarar como limitação: não há como auditar os dados de treino desses modelos

Arquitetura. Quatro componentes, na Figura 2. O executor expõe uma interface única para os quatro juízes e para o piso de regras, de modo que trocar de juiz não muda o resto do sistema.

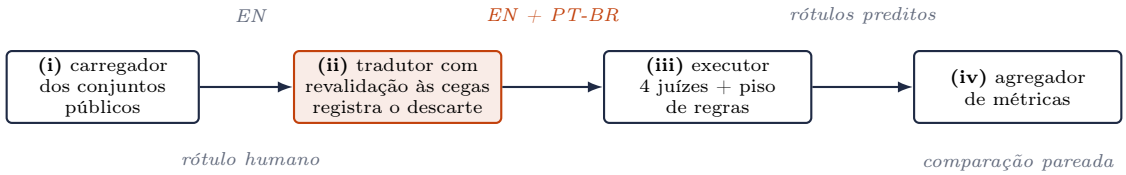


Figura 2: Arquitetura. O componente (ii), em destaque, é onde está o risco do projeto: o que não sobrevive à tradução é descartado ali.

Menor protótipo funcional. Um script que recebe um par (prompt, resposta) e um juiz e devolve o rótulo, somado a 100 pares traduzidos e revalidados. Isso já preenche a primeira célula da comparação e é entregável sozinho.

Avaliação. A solução funciona se reproduzir, dentro do erro esperado, os números publicados em inglês, e então medir a versão em português. As métricas são as da literatura, o que permite comparar direto com os números em inglês. A principal é a taxa de falso negativo, a fração de respostas nocivas que o juiz libera como seguras. Acompanham acurácia, F1, taxa de falso positivo e área sob a curva ROC, em que 0,5 equivale a sortear, mais o Kappa contra o rótulo humano, que mede concordância descontando o acerto por sorte. Os baselines são dois: o juiz de regras, como piso, e os valores publicados em inglês, como referência. Três experimentos: E1 reproduz o inglês e valida o ambiente; E2 mede o português no desenho pareado; E3, opcional, cruza língua com a reescrita de estilo de [3] para ver se os efeitos se somam.

Riscos e viabilidade. A Tabela 3 lista os riscos técnicos e a alternativa de cada um. O projeto cabe no semestre porque não treina modelo, não coleta dado novo e reusa protocolo publicado. Falta obter apenas tempo de GPU, já disponível no laboratório. O maior risco não é computacional, e sim a taxa de descarte na revalidação da tradução: se for alta, o conjunto final encolhe e a comparação perde poder estatístico. Por isso a primeira etapa do semestre é justamente medir esse descarte em uma amostra pequena, antes de traduzir o resto.

Referências

[1] Zheng, L., Chiang, W.-L., Sheng, Y., and others (2023). Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena. *NeurIPS 2023, Datasets and Benchmarks*. arXiv:2306.05685.

[2] Chao, P., Debenedetti, E., Robey, A., and others (2024). JailbreakBench: An Open Robustness Benchmark for Jailbreaking Large Language Models. *NeurIPS 2024, Datasets and Benchmarks*. arXiv:2404.01318.

[3] Eiras, F., Zemour, E., Lin, E., and Mugunthan, V. (2025). Know Thy Judge: On the Robustness Meta-Evaluation of LLM Safety Judges. *ICBINB Workshop @ ICLR 2025*. arXiv:2503.04474.

[4] Schwinn, L., Ladenburger, M., Beyer, T., Mofakhami, M., Gidel, G., and Günnemann, S. (2026). A Coin Flip for Safety: LLM Judges Fail to Reliably Measure Adversarial Robustness. arXiv:2603.06594.

[5] Brito, I. A., Rios, W. S. R., Dollis, J. S., Silva, D. F. C., and Galvão Filho, A. R. (2026). Safety Is Not Universal: The Selective Safety Trap in LLM Alignment. arXiv:2601.04389.

[6] Gu, J., Jiang, X., Shi, Z., and others (2024). A Survey on LLM-as-a-Judge. arXiv:2411.15594.

[7] Zhang, Q., Xiong, Z., and Mao, Z. M. (2024). LLM Safeguard is a Double-Edged Sword: Exploiting False Positives for Denial-of-Service Attacks. arXiv:2410.02916.

A Uso da IA na investigação

A investigação foi conduzida com o Claude, em rodadas de crítica e verificação. Os prompts principais foram: (i) "pesquise se não tem algo exatamente assim na literatura"; (ii) "verifique qualquer afirmação sem citação"; (iii) "leia todos os artigos que são citados completos, baixe e leia inteiro todos"; e (iv) "corrija qualquer erro".

O terceiro prompt foi o mais produtivo e mudou o resultado. Cada afirmação passou a ser conferida contra o artigo original, e não contra resumo ou trecho de busca. Três não sobreviveram à checagem. Primeiro, Zheng et al. [1] eram citados como evidência de que o juiz automático "virou padrão", mas o próprio artigo declara que não havia estudo sistemático do método, ou seja, ele propõe a técnica em vez de atestar sua adoção; a citação foi trocada. Segundo, um dado de anotação de Brito et al. [5] havia sido descartado como não confirmado, e o artigo confirma: três especialistas bilíngues, com 863 de 864 prompts validados no recorte em português. Terceiro, Zhang et al. [7] eram citados de forma larga, e verificou-se que cobrem a exploração de falsos positivos para negar serviço, mas não o laço adaptativo que se cogitava atacar.

A checagem nas fontes primárias também revelou a principal ameaça à validade do projeto, que nenhum resumo mostrava: Brito et al. descartaram deliberadamente a tradução automática por perda de carga cultural, e a proposta se baseia em traduzir. Isso não foi descartado como inconveniente, e sim incorporado como risco explícito, com a revalidação às cegas como controle e a taxa de descarte como resultado a reportar.

Sugestões descartadas na investigação, todas por viabilidade e não por mérito: otimizar sufixos adversariais por gradiente entre línguas, por custo computacional; envenenar o laço de adaptação de um limiar dinâmico de defesa, por exigir construir a defesa antes de atacá-la; e treinar um juiz próprio em português, porque treinar alteraria justamente o instrumento que o projeto se propõe a medir.