Juízes de segurança de LLM em português: especificação e plano experimental

Cristhian Kapelinski
Atividade 3: especificação e plano experimental

1 Especificação do problema

Todo número de segurança publicado sobre um modelo de linguagem é produzido por um *juiz*: outro modelo que classifica a resposta como nociva ou segura. Os juízes disponíveis foram construídos e validados em inglês, e a literatura já mostrou que eles quebram sob mudanças que não alteram o conteúdo julgado [3, 4]. Falta medir o que acontece quando o conteúdo está em português.

Tarefa do sistema. O sistema não é um juiz, é um *aferidor de juízes*. Ele recebe um conjunto de pares (prompt, resposta) com rótulo humano, submete cada par a vários juízes nas duas línguas e devolve o erro de cada juiz por língua.

Usuário. Quem precisa reportar segurança de assistentes em português e hoje não sabe a margem de erro do próprio instrumento: pesquisadores de segurança de IA e equipes que avaliam assistentes em produção.

Entrada e saída. A **entrada** é um par (prompt, resposta) e a identificação do juiz. A **saída imediata** é o rótulo binário nocivo ou seguro; a **saída agregada** é o relatório de métricas por juiz e por língua, com o teste de McNemar, que verifica se a diferença entre dois resultados medidos sobre os mesmos itens é maior do que o ruído da amostra.

A Tabela 1 delimita o que entra e o que fica fora.

Cenário de uso. Execução em lote, offline, sobre conjuntos com rótulo humano já existente. Não há usuário interativo nem serviço em tempo real.

Tabela 1: Escopo do projeto.

Dentro do escopo	**Fora do escopo**
Aferir juízes abertos já publicados	Treinar ou ajustar um juiz próprio
Português brasileiro contra inglês, em pares	Outras línguas, e variantes de português europeu ou africano
Turno único, texto apenas	Diálogo multiturno, imagem, áudio, cenário agêntico
Classificação binária de nocividade	Graduação de severidade e categorização de dano
Conjuntos públicos com rótulo humano	Coleta de dados novos, dados de usuários reais

2 Dados

Nenhum dado novo será coletado, e nenhuma anotação começará de zero. Isso é o que torna o projeto executável no semestre. A base são três conjuntos públicos que já trazem rótulo humano, listados na Tabela 2, e a contribuição é a versão em português validada.

Tabela 2: Conjuntos de dados. Formato de origem: JSON e CSV, um registro por par.

Conjunto	**Tamanho**	**Língua**	**Rótulo**	**Uso no projeto**
ReliableBench [4]	41 comportamentos	EN	humano	conjunto principal
JudgeStressTest [4]	971 amostras	EN	humano	casos difíceis de julgar
Comparação de juízes [2]	300 pares	EN	3 anotadores, 95% de acordo	referência de calibração
Versão PT-BR (a produzir)	**100 a 300 pares**	**PT-BR**	**revalidado às cegas**	**contribuição do projeto**

Preparação. Quatro passos: normalizar os três conjuntos em um esquema único (prompt, resposta, rótulo, comportamento, língua); traduzir para português com apoio de modelo e revisão humana; revalidar às cegas, reanotando sem ver o rótulo de origem; e descartar todo item em que o rótulo divergir, registrando a taxa de descarte.

Qualidade, viés e risco. O risco principal é a tradução. Brito et al. [5] descartaram deliberadamente a tradução automática ao montar um corpus bilíngue, porque a carga ofensiva depende da cultura e se perde no caminho. A revalidação às cegas é o controle contra isso, e a taxa de descarte é um resultado a reportar, não um detalhe interno. Há desbalanceamento conhecido entre itens nocivos e seguros, tratado por subamostragem equilibrada como em [3]. Há risco de contaminação, já que conjuntos públicos podem ter entrado no treino

dos próprios juízes, o que será declarado como limitação por não haver como auditar os dados de treino desses modelos. Sobre privacidade não há exposição: o conteúdo é sintético e público, sem dado pessoal. Sobre segurança, o material é ofensivo por construção e não será redistribuído.

3 Abordagem de IA

Técnica escolhida: prompting em inferência, sem treinamento. A Tabela 3 lista os juízes e o custo de memória de cada um. Os juízes serão executados como classificadores, com o prompt oficial de cada um e temperatura zero. Treinar ou ajustar um juiz alteraria justamente o instrumento que o projeto se propõe a medir, e com isso destruiria a comparabilidade com os números publicados. A razão da escolha é metodológica, não de custo. Não há RAG, porque a decisão depende só do par apresentado, sem conhecimento externo a recuperar.

Baseline. O juiz por casamento de palavras-chave, cujo desempenho já é conhecido: 56,0% de concordância com anotadores humanos [2], próximo de sortear. É o piso que qualquer juiz precisa superar para justificar seu custo.

Abordagem alternativa. Comitê por voto majoritário entre os quatro juízes. É a alternativa natural e será testada, mas com hipótese pessimista declarada: Schwinn et al. [4] mostram que a média entre juízes não corrige as falhas, porque eles erram de forma correlacionada. Medir isso em português é um resultado do projeto.

Tabela 3: Modelos e custo de memória. Precisão reduzida de 4 bits é a via para caber na GPU disponível.

Juiz	**Parâmetros**	**16 bits**	**4 bits**	**Papel**
Regras (casamento de termos)	—	—	—	baseline, piso de comparação
LlamaGuard-3	8 bilhões	≈16 GB	≈5 GB	juiz principal
Classificador HarmBench	13 bilhões	≈26 GB	≈8 GB	menor degradação em [3]
AegisGuard	7 bilhões	≈14 GB	≈5 GB	usado em [4]
JailJudge	7 bilhões	≈14 GB	≈5 GB	usado em [4]
Comitê por voto	—	—	—	**abordagem alternativa**

Métricas. Toda medida compara o rótulo do juiz com o rótulo humano. A *taxa de falso negativo* é a fração de respostas nocivas que o juiz libera como seguras, e é a que mais pesa em segurança; a *taxa de falso positivo* é o caso inverso, resposta segura barrada. O *F1* resume acerto e cobertura em um valor de 0 a 1, onde 1 é perfeito. A *área sob a curva ROC* mede a capacidade de separar as duas classes, onde 0,5 equivale a sortear. O *Kappa* mede concordância descontando o acerto por sorte, na mesma escala de 0 a 1.

Recursos computacionais. Uma GPU com memória suficiente para o maior juiz. O volume é de cerca de 300 pares vezes 2 línguas vezes 5 juízes, ou seja, na ordem de 3 mil inferências, executáveis em horas. Não há custo de interface paga.

4 Arquitetura

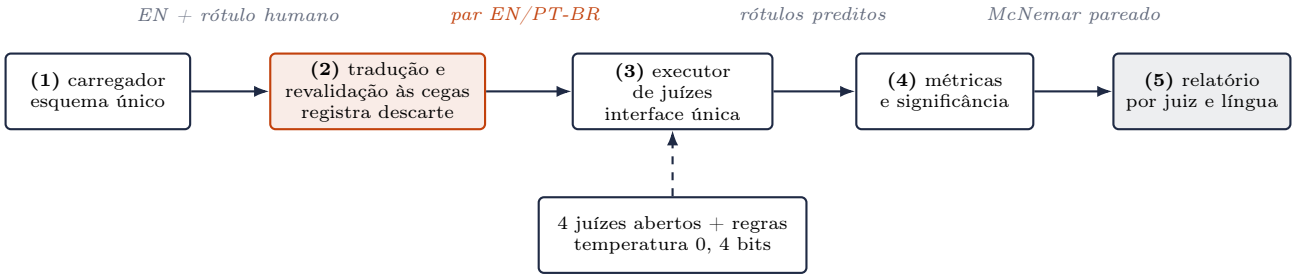


Figura 1: Arquitetura do protótipo. O componente (2), em destaque, concentra o risco do projeto.

A Figura 1 mostra o fluxo, que é linear e dá a cada componente uma responsabilidade só. O executor expõe uma interface única, de modo que acrescentar ou trocar um juiz não altera o resto do sistema.

5 Protótipo mínimo

O MVP é o menor caminho que produz um número comparável: um comando de linha que recebe um par (prompt, resposta) e um juiz e devolve o rótulo, mais 30 pares traduzidos e revalidados, mais o cálculo das

métricas sobre eles. Com isso a primeira célula da comparação entre línguas já existe, e a viabilidade do desenho inteiro fica demonstrada. A Tabela 4 separa o que é essencial do que vem depois.

Tabela 4: Recorte do MVP.

Essencial no MVP	**Depois do MVP**
Um juiz funcionando de ponta a ponta (LlamaGuard-3)	Os outros três juízes e o comitê por voto
30 pares em PT-BR revalidados	Corpus completo de 100 a 300 pares
Acurácia, F1, taxa de falso negativo e falso positivo	AUROC, Kappa, escore de concordância entre juízes
Execução manual por linha de comando	Automação em lote e retomada de execução
Comparação em uma língua	Desenho pareado completo com teste de significância

6 Plano experimental e critérios de sucesso

São cinco experimentos, resumidos na Tabela 5. E1 reproduz os valores publicados em inglês e valida o ambiente; E2 mede a degradação em português; E3 compara os juízes entre si e contra o baseline; E4 cruza língua com estilo; E5 compara precisão reduzida e precisão cheia. O desenho é pareado, pois o mesmo item aparece nas duas línguas, o que permite aplicar o teste de McNemar sobre as discordâncias, em vez de comparar duas proporções como se fossem independentes.

Tabela 5: Plano experimental. FN é a taxa de falso negativo, ou seja, resposta nociva liberada como segura.

Exp.	**Pergunta que responde**	**Comparação**	**Métrica de decisão**
E1	Os valores publicados em inglês são reproduzíveis?	nossos valores contra [3]	desvio absoluto por métrica
E2	Quanto o juiz muda quando o conteúdo está em português?	PT-BR contra EN, pareado	diferença de FN com intervalo
E3	Qual juiz degrada menos, e algum supera o baseline de regras?	4 juízes e o comitê contra regras	acurácia, F1, AUROC
E4	O efeito da língua se soma ao efeito de estilo?	2 por 2: língua e reescrita narrativa	interação sobre a FN
E5	Precisão reduzida degrada o julgamento?	4 bits contra 16 bits	variação de F1 por GB e por hora

Tabela 6: Critérios de sucesso, definidos antes da execução.

Critério	**Valor considerado satisfatório**	**Se não for atingido**
Reprodução do inglês (E1)	desvio de até 0,05 nas métricas de [3]	o ambiente está errado, e nada mais é confiável
Qualidade do corpus PT-BR	mínimo de 100 pares aprovados, com concordância de revalidação a partir de 0,80	reduzir a comportamentos sem carga cultural
Precisão da medida (E2)	intervalo de confiança da diferença de FN estreito o bastante para separar equivalência de degradação	ampliar o conjunto, ou reportar o intervalo obtido como limite do estudo
Utilidade dos juízes (E3)	todo juiz acima dos 56,0% de concordância do baseline [2]	o juiz não se justifica naquela língua, o que é achado
Custo (E5)	perda de F1 de até 0,02 ao usar 4 bits	executar em 16 bits e reduzir o número de juízes

Os critérios da Tabela 6 foram fixados antes da execução, e nenhum deles exige que exista diferença entre as línguas. Isso é deliberado, porque um critério que só se cumpre havendo efeito cria incentivo para encontrá-lo. Aqui qualquer direção é resultado: se os juízes degradarem em português, mede-se quanto; se se mostrarem equivalentes, a equivalência é igualmente publicável, já que hoje a confiabilidade em português é suposta e, até onde pudemos verificar, não foi medida. O que decide a qualidade do trabalho é a precisão da estimativa, não o sinal dela.

7 Planejamento do desenvolvimento

A Tabela 7 traz as etapas. A ordem é deliberada: a etapa 2 mede o descarte da tradução em uma amostra pequena antes de traduzir o resto, porque é o número que decide se o desenho principal continua de pé ou se o escopo precisa mudar. As etapas 6 e 7 são as que absorvem atraso.

Tabela 7: Etapas. O piloto da etapa 2 é o portão de decisão do projeto.

Etapa	Atividade	Semanas	Entregável
1	Ambiente, carregador e reprodução do inglês (E1)	2	E1 fechado e ambiente validado
2	**Piloto de tradução: 30 pares, medir descarte**	1	**taxa de descarte, decide o resto**
3	Baseline de regras e MVP com um juiz	2	MVP funcional
4	Corpus PT-BR completo e revalidado	3	corpus publicável
5	Demais juízes, comitê e experimentos E2 e E3	3	resultado principal
6	E4 e E5, se houver tempo	2	resultados complementares
7	Análise, escrita e documentação	2	relatório e repositório

8 Riscos e plano B

A Tabela 8 lista cada risco com sua alternativa. Os dois primeiros são de dados e concentram a maior ameaça, porque atingem o desenho pareado; os demais têm contorno direto.

Tabela 8: Riscos técnicos e alternativa para cada um.

Risco	Tipo	Plano B
Descarte alto na revalidação da tradução	dados	restringir a comportamentos sem carga cultural; reportar o descarte como achado central
Conjunto final pequeno demais para estimativa precisa	dados	incorporar os 300 pares de [2]; reportar o intervalo obtido e seu limite
GPU insuficiente para o juiz de 13 bilhões	recursos	precisão de 4 bits, ou usar somente juízes de até 8 bilhões
Juiz se recusa a julgar, como relatado em [2]	modelo	adotar o prompt específico do JailbreakBench, ou substituir o modelo
Conjunto público já usado no treino do juiz	dados	declarar como limitação: não há como auditar os dados de treino desses modelos
Atraso no cronograma	tempo	cortar E4 e E5, que são complementares; o resultado principal está em E2 e E3

9 Uso de IA

O Claude foi usado em três atividades distintas, com verificação em cada uma. Na **ideação**, para gerar e criticar alternativas de projeto; a primeira rodada foi descartada inteira por estar enviesada por anotações antigas, e o critério foi substituído por qual pergunta tem resposta imprevisível, o que eliminou três ideias de resultado óbvio. Na **investigação**, para busca e leitura de literatura, sob a regra de conferir cada afirmação contra o artigo original em vez de resumo ou trecho de busca; três não sobreviveram à checagem: Zheng et al. [1] eram citados como prova de que o juiz automático virou padrão, quando o artigo declara que não havia estudo sistemático do método; um dado de anotação de Brito et al. [5] havia sido descartado como não confirmado, e o artigo o confirma; e Zhang et al. [7] eram citados de forma larga demais. Na **especificação** desta atividade, para estruturar o plano experimental; a escolha do teste de McNemar foi mantida por ser a adequada ao desenho pareado, e a sugestão de treinar um juiz próprio em português foi descartada, porque treinar alteraria o instrumento que o projeto mede.

A verificação seguiu uma regra: nenhuma afirmação entra sem a fonte primária conferida. Isso mudou o projeto uma vez de forma relevante, quando a checagem revelou que Brito et al. evitaram tradução automática de propósito, o que virou o risco central do plano em vez de nota de rodapé.

Referências

[1] Zheng, L., Chiang, W.-L., Sheng, Y., and others (2023). Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena. *NeurIPS 2023, Datasets and Benchmarks*. arXiv:2306.05685.

[2] Chao, P., Debenedetti, E., Robey, A., and others (2024). JailbreakBench: An Open Robustness Benchmark for Jailbreaking Large Language Models. *NeurIPS 2024, Datasets and Benchmarks*. arXiv:2404.01318.

[3] Eiras, F., Zemour, E., Lin, E., and Mugunthan, V. (2025). Know Thy Judge: On the Robustness Meta-Evaluation of LLM Safety Judges. *ICBINB Workshop @ ICLR 2025*. arXiv:2503.04474.

[4] Schwinn, L., Ladenburger, M., Beyer, T., Mofakhami, M., Gidel, G., and Günnemann, S. (2026). A Coin Flip for Safety: LLM Judges Fail to Reliably Measure Adversarial Robustness. arXiv:2603.06594.

[5] Brito, I. A., Rios, W. S. R., Dollis, J. S., Silva, D. F. C., and Galvão Filho, A. R. (2026). Safety Is Not Universal: The Selective Safety Trap in LLM Alignment. arXiv:2601.04389.

[6] Gu, J., Jiang, X., Shi, Z., and others (2024). A Survey on LLM-as-a-Judge. arXiv:2411.15594.

[7] Zhang, Q., Xiong, Z., and Mao, Z. M. (2024). LLM Safeguard is a Double-Edged Sword: Exploiting False Positives for Denial-of-Service Attacks. arXiv:2410.02916.