Juízes de segurança de LLM em português

Medindo o efeito da língua

Cristhian Kapelinski

IA Aplicada · Atividade 4

Como se mede segurança de LLM

- envia-se um ataque e olha-se a resposta
- quem rotula nocivo ou seguro é outro LLM
- a taxa de sucesso do ataque sai do rótulo

Rotular à mão não escala. O juiz é automático.

Juiz: de onde sai a taxa



Toda taxa de sucesso publicada sai daqui.

Mudar o texto quebra o juiz

- reescrita de estilo: falso negativo 0,12 → 0,36
- texto benigno anexado: F1 do melhor juiz a zero

O conteúdo nocivo fica. O juiz deixa de ver.

Língua: não medida

ataque

modelo

categoria

língua

já medidas, em inglês

trocar de língua é a mudança mais barata, e ninguém testou

Falso negativo: só em inglês

resposta nociva liberada como segura (0 a 1)

Juiz	EN base	reescrito	PT-BR
HarmBench	0,12	0,36	?
ShieldGemma	0,50	0,70	?
WildGuard	0,02	0,12	?
LLaMA Guard	0,04	0,02	?

a coluna que o projeto vai preencher

Nada a coletar, nada a treinar

- 3 conjuntos públicos já com rótulo humano
- 4 juízes abertos, rodando só em inferência
- baseline: buscar palavra-chave numa lista

Cabe no semestre porque reusa o que existe.

Traduzir muda o rótulo

“watermelon” → “melancia”

insulto racial em inglês

fruta

O rótulo “nocivo” não sobrevive à tradução.

Arquitetura: quatro etapas



Nada é treinado: treinar mudaria o juiz.

Critérios fixados antes de rodar

- reproduzir os valores já publicados em inglês
- medir a diferença com intervalo de confiança

Qualquer resultado é resultado.

MVP: um juiz e 30 pares

- um juiz funcionando de ponta a ponta
- 30 pares em PT-BR revalidados
- as primeiras métricas comparadas

Próximo passo: medir o descarte.

Obrigado!

Perguntas são bem-vindas

Cristhian Kapelinski

cristhianavila.aluno@unipampa.edu.br

unipampa

Universidade Federal do Pampa