Juízes de segurança de LLM em português: segunda entrega, como e a que custo traduzir

Cristhian Kapelinski

Atividade 6: segunda entrega do projeto

1 O que mudou desde a Atividade 5

A Atividade 5 entregou o piloto de traduzibilidade e projetou descarte nulo, 0 de 30, para o corpus de dano operacional. A conclusão de lá foi direta: o rótulo deve sobreviver à tradução, então o passo seguinte é executar a tradução do corpus. Isso abre uma decisão que a A5 não respondeu: com qual método traduzir, a que custo e com qual qualidade. Esta entrega investiga essa decisão, com preços verificados, estimativa de tokens do corpus real e um teste concreto de um tradutor dedicado contra um LLM. O achado principal muda a forma de pensar o passo: no subconjunto difícil de julgar o custo é desprezível em qualquer método, e mesmo no conjunto completo o LLM barato fica na casa de poucos dólares, então a escolha se decide por qualidade, controle e privacidade, não por preço.

2 Métodos considerados

Três famílias, com naturezas diferentes. **LLM instruível**, como DeepSeek, Gemini, GPT e Claude: aceita instrução, então dá para pedir que não suavize nem endureça o conteúdo e que mantenha código e números, o que interessa diretamente à preservação do rótulo medida na A5. **Tradução automática dedicada**, como Google Cloud Translation, DeepL, Azure e Amazon: motor de tradução puro, determinístico e forte em fluência, mas sem como receber a instrução de preservar um sinal deliberado. **Modelos abertos auto-hospedados**, como NLLB-200, Opus-MT e Argos: custo de API zero e nenhum dado sai para terceiros, o que importa aqui porque o conteúdo é material nocivo de benchmark, mas exigem GPU e configuração e tendem a fluência menor.

3 Estimativa de tokens e custo do corpus

Os tokens não vêm de heurística: foram contados com um tokenizador real, o `o200k_base`, sobre o texto do corpus, e a razão saída sobre entrada foi medida no teste com o DeepSeek. A Tabela 1 traz as medições. Uma primeira versão usava a regra de bolso de 4 caracteres por token, que superestimou a entrada em cerca de 15 por cento; os números abaixo já estão corrigidos.

Tabela 1: Medições, não estimativas. Tokens de entrada contados com o tokenizador o200k sobre o texto real; razão saída sobre entrada medida no teste com o DeepSeek.

Medição	**Valor medido**
Densidade de token, corpus real	4,60 caracteres por token
Tokens de entrada, JudgeStressTest 439	151.962
Tokens de entrada, CoinflipForSafety completo 6.560	2.504.123
Razão saída sobre entrada, PT sobre EN	1,18 (medido no DeepSeek)
Sobrecarga de instrução por chamada	cerca de 55 tokens

4 Tabela comparativa de custo

A Tabela 2 traz o custo total em dois escopos medidos por inteiro, ambos do mesmo artigo: o subconjunto de casos difíceis de julgar, com 439 pares (JudgeStressTest), e o conjunto completo de 6.560 pares (CoinflipForSafety), que o contém, com os preços de setembro de 2026.[1] O escopo completo usa a versão do *CoinflipForSafety* publicada no HuggingFace (`ASSELab/CoinflipForSafety`), que traz a resposta do modelo para os 6.560 pares. O arquivo `a_coinflip_judge_data.csv` do repositório no GitHub vem sem a coluna de resposta, só com o prompt e os rótulos; medir sobre ele contaria apenas o pedido e subestimaria o volume, e com ele o custo. Como o experimento é julgar a resposta traduzida, o escopo tem de incluir a resposta, e por isso a medição é feita sobre a versão do HuggingFace.

[1] Preços por token: DeepSeek, Gemini, OpenAI, Anthropic. Por caractere: Google Cloud Translation, DeepL, Amazon, Azure. Verificados em setembro de 2026; a linha do Gemini foi reconferida em outubro de 2026.

Tabela 2: Custo total da tradução, em dólares, com tokens medidos (o200k) sobre o corpus inteiro, em dois escopos do mesmo artigo: o subconjunto difícil de julgar JudgeStressTest (439 pares) e o conjunto completo CoinflipForSafety (6.560 pares) que o contém. Os dois trazem a resposta do modelo. LLMs cobram por token, tradutores dedicados por caractere. DeepSeek Flash na faixa off-peak a peak.

Método	**Família**	**439**	**6.560**
NLLB-200 / Opus-MT / Argos	aberto	0	0
DeepSeek V4.1-Flash	LLM	0,13 a 0,26	2,15 a 4,30
GPT-5.4 Nano	LLM	0,25	4,19
Gemini 3.1 Flash-Lite	LLM	0,31	5,06
GPT-5.4 Mini	LLM	0,46	7,60
Gemini 3.5 Flash-Lite	LLM	0,49	8,14
DeepSeek V4-Pro	LLM	0,91	15,01
Claude Haiku 4.5	LLM	1,05	17,28
Claude Sonnet 4.6	LLM	3,15	51,84
DeepL API Pro	dedicada	3,84	63,90
Azure Translator	dedicada	6,99	116,40
Amazon Translate	dedicada	10,48	174,60
Google Cloud Translation	dedicada	13,97	232,80

Duas leituras saltam. A primeira, sobre escala: no subconjunto difícil de 439 pares nenhum método passa de quatorze dólares, então ali o custo não decide nada; já no conjunto completo, de 6.560 pares com resposta, a tradução dedicada chega a duzentos e trinta e três dólares no Google, enquanto o LLM barato fica em poucos dólares, cerca de dois a quatro no DeepSeek. A segunda é estrutural e explica a primeira: os LLMs baratos saem de trinta a cem vezes mais baratos que as APIs de tradução dedicada, porque estas cobram por caractere, cerca de cinco a vinte dólares por milhão, enquanto um token barato de LLM equivale a poucos centavos por milhão de caracteres. O motor dedicado, historicamente a opção óbvia para traduzir em escala, é aqui o mais caro, e a diferença só vira dinheiro de verdade quando o corpus cresce.

Cada linha traz a versão do modelo que a cobra, e são as servidas pela API em outubro de 2026. O Gemini entra com a 3.1 Flash-Lite, não com a 2.5 Flash-Lite que uma versão anterior desta conta usava: a 2.5 Flash-Lite, embora mais barata a 0,10 por 0,40 dólar por milhão de tokens, é descontinuada em 16 de outubro de 2026, então cotá-la seria cotar um preço que a API deixa de atender. A troca não muda a leitura: no conjunto completo o Gemini fica em cinco dólares, ainda uma ordem de grandeza abaixo dos duzentos e trinta e três do Google.

Uma ressalva importante sobre o Google, porque há dois produtos com o mesmo nome. O Google Tradutor para uma pessoa, no site ou no aplicativo, é gratuito e sem limite prático, mas serve para traduzir à mão, não para rodar um corpus por programa. O que a Tabela 2 custeia é a *Google Cloud Translation API*, a via oficial para tradução automatizada, que é paga, vinte dólares por milhão de caracteres, com os primeiros 500 mil por mês grátis. O teste desta entrega usou o endpoint web gratuito e não oficial, que funciona para poucas frases, mas não é rota sancionada para o corpus inteiro, tem limite de taxa e pode quebrar. Na prática, dá para testar o Google de graça, mas traduzir o corpus inteiro pela via oficial é pago. A cota gratuita de 500 mil caracteres por mês não cobre nem o subconjunto de 439 pares, de 699 mil caracteres, nem o completo de 6.560, de 11,6 milhões.

5 Teste real: tradutores testados

Testei seis tradutores de verdade, das três famílias. Dois LLMs, o Claude e o DeepSeek pela sua API com o modelo `deepseek-chat`; a tradução dedicada, pelo Google; e os três abertos, Argos, Opus-MT e NLLB-200, rodando localmente na CPU. Desta vez os itens de payload operacional, malware e síntese, entraram no teste, porque são justamente os que mais podem quebrar um tradutor. A Tabela 3 traz a cobertura: os motores locais e o DeepSeek traduzem tudo o que recebem, incluindo os quatro operacionais. Para os exemplos, o envio a serviços externos ficou restrito aos trechos benignos; dos operacionais só se registrou o desfecho, traduziu ou não, nunca o texto. Todos preservam o sinal de segurança nos trechos benignos, como mostra a Tabela 5: a cautela continua cautela, a diferença é estilística. O motor dedicado e os abertos são mais literais; os dois LLMs são mais naturais e, o que importa para o projeto, aceitam a instrução de manter código e números e de não suavizar, coisa que os outros não aceitam.

Com a vazão medida nesse teste dá para projetar quanto levaria rodar os dois conjuntos inteiros nos motores abertos locais, na CPU e sem custo de API. O Argos, a cerca de 1,2 segundo por par, levaria uns 9 minutos nos 439 pares e cerca de 2 horas nos 6.560; o Opus-MT, a 1,8 segundo por par, uns 13 minutos e 3 horas; o NLLB-200, bem mais lento a 12 segundos por par, cerca de 1,5 hora nos 439 e 22 horas nos 6.560, o que o inviabiliza para o conjunto completo sem GPU. Os motores abertos custam zero de API, então o preço deles é esse tempo de máquina; os LLMs e os dedicados cobram o valor da Tabela 2 e rodam em paralelo pela API, com o gargalo em dinheiro, não em tempo. A Tabela 4 reúne a projeção.

Tabela 3: Cobertura dos tradutores, com os itens operacionais incluídos. Motores abertos rodam localmente na CPU; do DeepSeek registrou-se só o desfecho por item, sem o texto. O NLLB foi medido em uma amostra por ser lento na CPU.

Motor	**Onde roda**	**Traduzidos**	**Tempo**
Argos (aberto)	local, offline (CPU)	30 de 30	35 s
Opus-MT (aberto)	local, offline (CPU)	30 de 30	53 s
NLLB-200 (aberto)	local, offline (CPU)	10 de 10 (amostra)	120 s
DeepSeek (LLM, API)	remoto	30 de 30	

Tabela 4: Projeção de tempo e custo para traduzir cada conjunto inteiro, a partir do que foi rodado: o tempo dos abertos vem da vazão medida na CPU; o custo vem da Tabela 2. O tempo de API dos LLMs e dedicados não foi medido, mas é paralelizável.

	439 pares		**6.560 pares**	
Motor	**tempo**	**custo**	**tempo**	**custo**
Argos (aberto, CPU)	~9 min	US$ 0	~2,1 h	US$ 0
Opus-MT (aberto, CPU)	~13 min	US$ 0	~3,2 h	US$ 0
NLLB-200 (aberto, CPU)	~1,5 h	US$ 0	~22 h	US$ 0
DeepSeek V4.1-Flash (API)	paralelo	US$ 0,13 a 0,26	paralelo	US$ 2,15 a 4,30
Google Cloud (API)	paralelo	US$ 13,97	paralelo	US$ 232,80

Risco da tradução por LLM

O LLM é o único tradutor que pode se recusar a traduzir, porque o conteúdo do corpus é, por construção, um ataque, e uma recusa devolve texto fora do tema que corromperia o dado em silêncio. Medi esse risco de fato: o DeepSeek traduziu os 30 itens, inclusive os 4 de payload operacional, sem nenhuma recusa. Mas o resultado depende do modelo e do prompt, um modelo com alinhamento mais rígido ou um prompt sem enquadramento claro de tradução pode recusar, então a recusa entra como risco a monitorar, com detecção automática e reserva em outro motor. Os tradutores dedicados e os abertos não têm esse risco: não são modelos de instrução alinhados à segurança, então traduzem qualquer entrada, como confirmam os 30 de 30 do Argos e do Opus-MT.

Tabela 5: O mesmo trecho seguro traduzido pelos seis tradutores testados. Todos preservam o caráter de cautela.

Fonte (EN)	*Just a quick note of caution: please be careful with any links or attachments in emails, as they can sometimes be unsafe.*
Google Tradutor (dedicada)	Apenas uma rápida nota de cautela: tenha cuidado com quaisquer links ou anexos em e-mails, pois às vezes eles podem ser inseguros.
Claude (LLM)	Só um aviso rápido: tenha cuidado com links ou anexos em e-mails, que às vezes não são seguros.
DeepSeek (LLM, API)	Só um rápido aviso de cautela: por favor, tome cuidado com quaisquer links ou anexos em e-mails, pois às vezes eles podem ser inseguros.
Argos (aberto, local)	Apenas uma rápida nota de cuidado: por favor, tenha cuidado com quaisquer links ou anexos em e-mails, pois eles podem às vezes ser inseguros.
Opus-MT (aberto, local)	Apenas uma nota rápida de cautela: por favor, tenha cuidado com quaisquer links ou anexos em e-mails, pois eles às vezes podem ser inseguros.
NLLB-200 (aberto, local)	Apenas uma breve nota de cautela: por favor, tenha cuidado com quaisquer links ou anexos nos e-mails, pois às vezes podem ser inseguros.

6 Leitura e recomendação

Como o custo é desprezível, a decisão passa a ser de qualidade, controle e privacidade, e cada família tem uma troca própria, resumida na Tabela 6.

Por isso a recomendação deixa de ser um tradutor único e passa a ser um pequeno conjunto, dois a três motores de famílias diferentes, todos baratos. Um LLM instruível, DeepSeek Flash ou Gemini 3.1 Flash-Lite, pela fidelidade e pela instrução de preservar código e rótulo. Um tradutor aberto local, Opus-MT ou Argos, como reserva privada que nunca recusa e cobre o item quando o LLM falha. E o Google como referência de fluência para auditar uma amostra. O custo somado continua baixo mesmo no conjunto completo, e o conjunto de motores dá resiliência: se o LLM recusar um item, o motor aberto assume, e a discordância entre motores sinaliza os casos difíceis de traduzir, que merecem revisão humana. Para reprodutibilidade, cada motor entra com versão e prompt presos, para que a mesma tradução saia amanhã.

Tabela 6: Prós e contras por família de tradutor.

Família	**Prós**	**Contras**
LLM instruível	aceita instrução, mantém código e números, não suaviza; fluente; barato	pode recusar ou desviar em conteúdo adversarial, corrompendo o dado; custo por token varia por fornecedor
Tradução dedicada	determinística, forte em fluência, nunca recusa	não aceita instrução; paga; envia o conteúdo a terceiros
Aberto, auto-hospedado	grátis, privado e offline, nunca recusa; reprodutível com versão presa	mais lento na CPU, fluência um pouco menor; exige GPU ou paciência

7 Uso de IA e verificação

Os preços foram verificados por busca nas páginas dos fornecedores e em rastreadores de preço, em setembro de 2026, com a linha do Gemini reconferida em outubro quando a 2.5 Flash-Lite foi marcada para descontinuação, e conferidos entre si. Os tokens foram contados com o tokenizador o200k sobre o texto real do corpus, não por regra de bolso, incluindo o conjunto completo na versão do HuggingFace que traz as respostas, e a razão saída sobre entrada foi medida no teste com o DeepSeek. Os testes de tradução foram executados de fato: o Google Tradutor pela interface pública, o Claude pelo próprio assistente, o DeepSeek pela API, e os três abertos, Argos, Opus-MT e NLLB-200, rodando localmente na CPU. O teste de recusa exigiu enviar também os itens operacionais ao DeepSeek, mas dele se registrou apenas o desfecho, traduziu ou não, e a tradução em si foi descartada, nunca gravada nem incluída no repositório. Os exemplos de tradução mostrados usam só os trechos benignos.

8 Artefatos

Na pasta `atividade6/`: `precos.csv` lista os preços por método com a fonte; `tokens_medidos.json` traz a contagem de tokens do corpus; `teste_deepseek.json`, `teste_comparativo.json` e `teste_abertos.json` trazem os trechos seguros traduzidos pelos tradutores testados, com os tokens reais da API do DeepSeek e a cobertura dos abertos; `risco_llm.json` traz o desfecho por item do teste de recusa, sem o texto traduzido; e `custo_medido.py` recomputa a Tabela 2 a partir dos tokens medidos e da razão medida.