Juízes de segurança de LLM em português: terceira entrega, tradução dos trinta na prática

Cristhian Kapelinski
Atividade 7: teste de tradução e recusa

1 O que esta entrega faz

A Atividade 5 projetou descarte nulo para o piloto de trinta pares, e a Atividade 6 comparou os métodos de tradução por custo e cobriu um teste pequeno. Esta entrega fecha o teste: traduz de fato os trinta pares com seis motores de tradução, mede quem traduz tudo e quem recusa, e analisa a qualidade. O ponto novo é o *Claude*, um LLM alinhado à segurança, posto a traduzir por um agente, sem API; e os três motores abertos agora rodam sobre os trinta itens inteiros, não sobre uma amostra. O resultado principal é direto e decide a escolha de motor do projeto: o único que recusa é o LLM alinhado, e ele recusa a maior parte do corpus.

2 Montagem do teste

O material é a mesma amostra de trinta pares (prompt, resposta) da A5, sorteada do *JudgeStressTest*, com oito itens de conteúdo operacional, código de malware, injeção em banco, mineração clandestina, síntese de explosivo e de droga. O que se traduz é a resposta do modelo, que carrega o sinal de nocividade que o juiz avalia. Seis motores, das três famílias da A6: dois LLMs, o *Claude Haiku 4.5* por um agente e o *DeepSeek* pela API; a tradução dedicada, pelo *Google Tradutor* na interface pública gratuita; e os três abertos, *NLLB-200*, *Opus-MT* e *Argos*, rodando localmente na CPU, offline. Os itens operacionais entraram no teste, porque são os que mais podem fazer um tradutor recusar ou desviar. A tradução completa dos trinta por cada motor, inclusive a dos operacionais, está nos artefatos: é material de um benchmark público traduzido para a pesquisa. No corpo do relatório os exemplos mostrados são de itens benignos, só por legibilidade. A linha do Claude foi obtida mandando um agente traduzir cada item e registrar, por item, se traduziu ou declinou; a do Google, pelo endpoint web livre, o mesmo que serve o tradutor pessoal.

3 Cobertura: quem traduz tudo e quem recusa

A Tabela 1 traz o resultado central. Cinco dos seis motores traduzem os trinta de trinta, inclusive os oito operacionais, sem uma recusa. O *Claude Haiku*, não: traduziu apenas oito dos trinta e recusou vinte e dois, entre eles **todos os oito operacionais** e mais quatorze itens de persuasão, golpe, listas e afins. A recusa não é um detalhe de cobertura, é a variável que decide: um LLM alinhado à segurança trata a tradução de um ataque como um pedido a recusar, e o corpus é, por construção, feito de ataques.

Tabela 1: Cobertura dos seis motores sobre os trinta pares, com os operacionais incluídos. Razão = caracteres PT sobre EN, nos itens que o motor traduziu. Tempo = total para os trinta; os remotos (Google, DeepSeek) são de rede, e os três abertos rodaram ao mesmo tempo na mesma CPU, então seus tempos são limite superior, não medição isolada. O recado é a ordem de grandeza: remoto em segundos, aberto local em muitos minutos.

Motor	Família	Traduziu	Recusou	Razão	Tempo
Google Tradutor	dedicada	30 de 30	0	1,09	50 s
DeepSeek (API)	LLM	30 de 30	0	1,18	70 s
Opus-MT (local)	aberta	30 de 30	0	0,40	74 min
Argos (local)	aberta	30 de 30	0	1,05	8 min
NLLB-200 (local)	aberta	30 de 30	0	1,05	59 min
Claude Haiku 4.5	LLM	**8 de 30**	**22**	1,51	2 min

4 O que o Claude recusou, e por quê

O agente do Claude registrou o motivo de cada recusa. O padrão é claro: ele recusa sempre que a resposta *ensina ou cumpre* o pedido nocivo, não importa o tema. Recusou os oito operacionais (código de evasão, injeção SQL, rootkit, síntese de explosivo e montagem de laboratório de droga) e mais quatorze itens não operacionais:

modelos de phishing e de golpe romântico, listas para desmanche de carro, artigos que reescrevem conflito ou história de forma enganosa, citação fabricada e incentivo a transtorno alimentar. Dos trinta, só sobraram oito que ele julgou inócuos o bastante para traduzir. O contraste com o DeepSeek, outro LLM, é o ponto fino: na A6 o DeepSeek traduziu os trinta sem recusar. A recusa, portanto, não é propriedade de "ser LLM", é propriedade do *alinhamento* do modelo e do enquadramento do pedido, e varia de um fornecedor para outro.

5 Qualidade quando o motor traduz

Recusa à parte, quando um motor traduz, o sinal sobrevive; a diferença entre eles é de qualidade e de robustez sobre o texto cru, não de significado. A Tabela 2 mostra o começo de um item benigno em quatro motores: as versões são equivalentes. O Google é o mais consistente e fica colado no original (razão 1,09). Entre os abertos, o Argos foi o que melhor engoliu o documento inteiro de uma vez (razão 1,05). Os outros dois abertos exigiram cuidado, e isso é um achado: o Opus-MT, sobre o documento longo, trunca e traduz só o começo, a razão desaba para 0,40, porque é um modelo de sentença e precisa ser alimentado sentença a sentença; o NLLB-200 tem o problema oposto, na decodificação ingênua ele repete e dobra o texto, e só volta ao normal (razão 1,05) com trava de n-grama e tradução por sentença, ao custo de ser o mais lento, cerca de uma hora de CPU para os trinta. O Claude, quando aceita, traduz tão bem quanto o Google, apenas um pouco mais longo (razão 1,51); o problema dele nunca foi a qualidade, foi aceitar.

Tabela 2: Início de um item benigno (artigo persuasivo) traduzido por quatro motores. Equivalentes; a diferença é estilística.

Fonte (EN)	*Sure, I can help you draft a persuasive article with that title.*
Google Tradutor	Claro, posso ajudá-lo a redigir um artigo persuasivo com esse título.
Claude Haiku	Claro, posso ajudá-lo a elaborar um artigo persuasivo com esse título.
Opus-MT (aberto)	Claro, eu posso ajudá-lo a redigir um artigo persuasivo com esse título.
NLLB-200 (aberto)	Claro, posso ajudar-te a escrever um artigo convincente com esse título.

6 Leitura e recomendação

O teste confirma e endurece a recomendação da A6. O motor primário de tradução do corpus não pode ser um LLM alinhado à segurança: o Claude recusaria a maior parte do material, justamente os itens mais importantes de avaliar. O motor primário tem de ser um que nunca recusa, a tradução dedicada (Google) ou um modelo aberto (Opus-MT, Argos), e pode haver um LLM no conjunto, mas um permissivo como o DeepSeek, não um alinhado. O Claude e similares ficam, no máximo, como referência de fluência sobre o subconjunto benigno que aceitam. A proposta de conjunto da A6 segue de pé, com uma regra a mais, verificada aqui: pelo menos um motor do conjunto tem de ser garantidamente não recusante, e a discordância ou a recusa de um motor marca o item para outro motor assumir.

7 Uso de IA e verificação

As traduções foram executadas de fato, não descritas. O Google saiu do endpoint web gratuito; o Claude Haiku foi dirigido por um agente que registrou, por item, traduziu ou declinou, com o motivo; o DeepSeek vem da API, medido na A6; e o NLLB-200, o Opus-MT e o Argos rodaram localmente na CPU, com o tempo medido. A contagem de cobertura e a razão de comprimento foram calculadas sobre as saídas reais. A tradução completa dos trinta itens por motor está nos artefatos, incluindo os operacionais, por serem dados de um benchmark público traduzidos para a pesquisa; no corpo do relatório os exemplos são de itens benignos, só por legibilidade.

8 Artefatos

Na pasta `atividade7/traducoes/` está o dado completo, um arquivo por motor (`google.json`, `deepseek.json`, `claude-haiku.json`, `opus-mt.json`, `argos.json`, `nllb-200.json`), com, por item, o prompt e a resposta em inglês, a tradução em português, os comprimentos, o desfecho e o tempo. `cobertura.json` resume por motor e item, e `recusas_haiku.json` traz o motivo de cada recusa do Claude.