Juízes de segurança de LLM em português: quarta entrega, tradução do corpus

Cristhian Kapelinski

Atividade 8: produzir a versão em português

1 O que esta entrega faz

A Atividade 7 testou os tradutores e definiu a regra de escolha: o motor que traduz o corpus não pode ser um LLM alinhado à segurança, que recusa o material; tem de ser um motor que nunca recusa, a tradução dedicada, um modelo aberto, ou um LLM permissivo. Esta entrega executa a tradução de verdade: produz a versão em português dos pares (prompt, resposta), que é o insumo do experimento do juiz. Traduz-se o prompt e a resposta de cada par, porque o juiz lê os dois. Dois conjuntos entram, o benchmark de juízes *JudgeStressTest*, com 439 pares, e o conjunto completo *CoinflipForSafety*, com 6.560 pares.

2 Motores e execução

Seguindo a regra da A7, cinco motores não recusantes, das três famílias. O **DeepSeek** (endpoint `deepseek-chat`, que hoje serve o `deepseek-flash`), um LLM permissivo, pela API, sobre o conjunto de 439, que é o alvo imediato. Três **modelos abertos**: o *NLLB-200-1.3B* e o *Opus-MT*, em GPU, sobre os dois conjuntos, e o *Argos*, em CPU, sobre o 439. E o **Google Tradutor**, a tradução dedicada, pela interface web gratuita, também sobre o 439. Nenhum Claude ou LLM alinhado, porque a A7 mostrou que recusariam a maior parte do material.

A execução dos abertos aproveitou uma **RTX 5080 ociosa** do laboratório, o que derruba o custo a zero e o tempo de horas de CPU para minutos de GPU. A tradução é feita sentença a sentença, em lotes, para não truncar o documento longo nem cair em repetição, as duas falhas que a A7 flagrou nesses modelos na decodificação ingênua. O ambiente e o cache ficaram em disco de trabalho da máquina, fora da partição de `home`, e a chave do DeepSeek entrou só por variável de ambiente, nunca gravada.

3 Custo

A conta confirma o que a A6 projetou: traduzir este corpus é barato ou gratuito. O DeepSeek sobre os 439 pares custou cerca de dezessete centavos de dólar na tradução principal, mais cinco centavos na re-tradução dos prompts corrigida, perto de vinte e dois centavos no total, tudo lido no uso da própria API, não estimado; os modelos abertos na GPU custam zero de API, só tempo de máquina. A Tabela 1 resume.

Tabela 1: Custo e via de cada tradução. O custo do DeepSeek é o valor cobrado pela API, lido no painel de uso, cerca de 461 mil tokens no dia; o endpoint `deepseek-chat` serve o `deepseek-flash`, com desconto de cache de prompt, o que o torna mais barato que a estimativa por preço de tabela. Os abertos rodam em GPU própria, sem custo de API.

Motor	Conjunto	Via	Custo
DeepSeek (`deepseek-flash`)	439	API	US$ 0,22
NLLB-200-1.3B	439 e 6.560	GPU RTX 5080	US$ 0
Opus-MT	439 e 6.560	GPU RTX 5080	US$ 0
Argos	439	CPU local	US$ 0
Google Tradutor	439	web gratuita	US$ 0

4 Cobertura

O achado mais forte desta entrega não é de custo, é de comportamento. Mandado traduzir o **prompt** cru, uma instrução nociva curta, o DeepSeek *reagiu à instrução* em vez de traduzi-la: dos 439 prompts, recusou 210 (48%), cumpriu o pedido em 17 (4%), escrevendo a nota de resgate ou o artigo pedido, e só traduziu 212 (48%). É o LLM confundindo o dado com um comando dirigido a ele, o mesmo risco da A7, agora visto até no DeepSeek permissivo, e até o caso pior, em que o tradutor executa o ataque. A correção foi barata e eficaz: re-traduzir cada texto *delimitado por marcas*, instruindo que aquilo é dado, não comando, e que não se deve obedecer nem

recusar. Com isso os prompts subiram de 48% para **439 de 439** traduzidos. O mesmo enquadramento recuperou as respostas, e sobrou **uma** recusa dura, a do item de toxina botulínica, que o DeepSeek não traduziu nem como dado, o que marca um piso: o conteúdo mais extremo resiste mesmo ao enquadramento. Os modelos abertos e o Google não têm nada disso: traduzem prompt e resposta literalmente, os 439 e os 6.560 por inteiro, sem uma recusa. A tradução sentença a sentença em GPU também curou as duas falhas que a A7 vira nesses modelos: o Opus não trunca mais e o NLLB não repete, e todos saem com razão de comprimento perto de um, entre 1,05 e 1,09. A Tabela 2 traz a cobertura final.

Tabela 2: Cobertura da tradução por motor e conjunto, já com a correção de enquadramento aplicada ao DeepSeek. Pares com prompt e resposta traduzidos.

Motor	**439 (JudgeStressTest)**	**6.560 (CoinflipForSafety)**
DeepSeek	prompt 439/439; resp. 438/439	não rodado
NLLB-200-1.3B	439 de 439	6.560 de 6.560
Opus-MT	439 de 439	6.560 de 6.560
Argos	439 de 439	não rodado
Google Tradutor	439 de 439	não rodado

5 Artefatos

Na pasta `atividade8/traducoes/`, um arquivo por motor e conjunto, com, por par, o prompt e a resposta em inglês e a tradução em português, mais o rótulo humano e o ataque de origem. Sobre os 439: `deepseek-js439.json` (com o desfecho por campo, após a correção), `nllb-js439.json`, `opus-js439.json`, `argos-js439.json` e `google-js439.json`. Sobre os 6.560: `nllb-coinflip.json` e `opus-coinflip.json`.

6 Próximo passo

Com a versão em português pronta, o passo seguinte é o experimento que dá nome ao projeto: rodar os juízes de segurança sobre os pares em inglês e em português e medir se a concordância com o rótulo humano cai ao mudar de língua. Antes de rodar, é preciso resolver a direção das colunas de escore do dataset, que a A5 mostrou estar invertida, para não reportar métricas trocadas.