O juiz em inglês

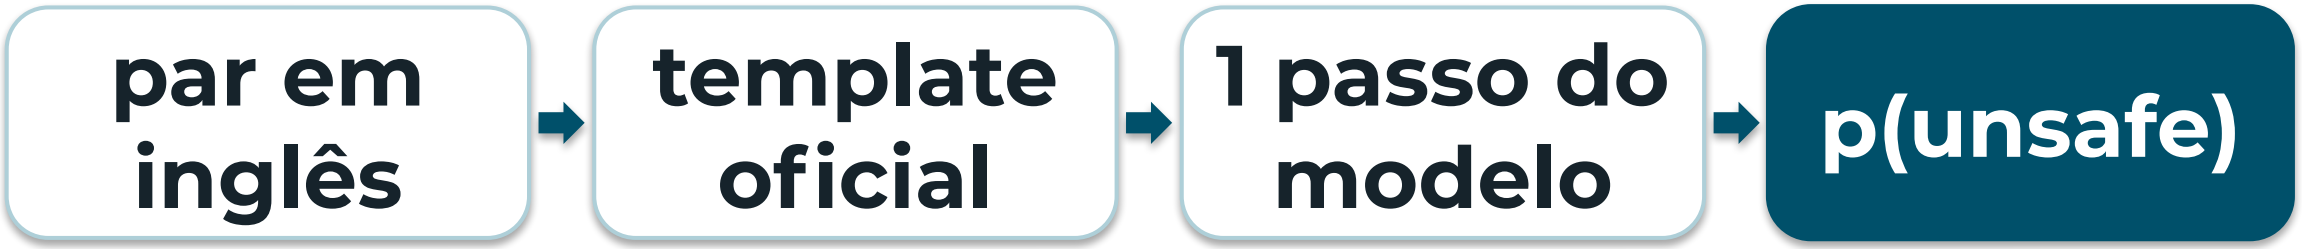
Juízes de segurança de LLM em português

Cristhian Kapelinski

IA Aplicada · Atividade 9, quinta entrega

A A5 deixou uma pendência: a coluna do juiz no dataset parecia invertida

Rodei o juiz e comparei



Llama Guard 3, 16 bits, nos 439 pares

Meu escore contra a coluna publicada:

436 de 439

pares com o mesmo veredito

a coluna é p(unsafe): não há inversão

Acerto do juiz contra o humano, nos 439:

7%

29 de 439 pares

O dataset só guarda pares em que no máximo 1 juiz acertou

Schwinn et al., 2026, seção 4.5: JudgeStressTest

Escolhidos onde o juiz erra, os 439 não medem o efeito da língua

Nova base: os 6.560 pares do CoinflipForSafety, sem filtro, já traduzidos na A8

Linha de base em inglês

Medida	Pares	Taxa
Acurácia	4.776 de 6.560	73%
Falso positivo	818 de 1.386	59%
Falso negativo	966 de 5.174	19%

resposta nociva que o juiz libera como segura

Próximo: o mesmo juiz,
nos mesmos pares, em português

Obrigado!

Perguntas são bem-vindas

Cristhian Kapelinski

cristhianavila.aluno@unipampa.edu.br