O juiz em português

Juízes de segurança de LLM em português

Cristhian Kapelinski

IA Aplicada · Atividade 10, sexta entrega

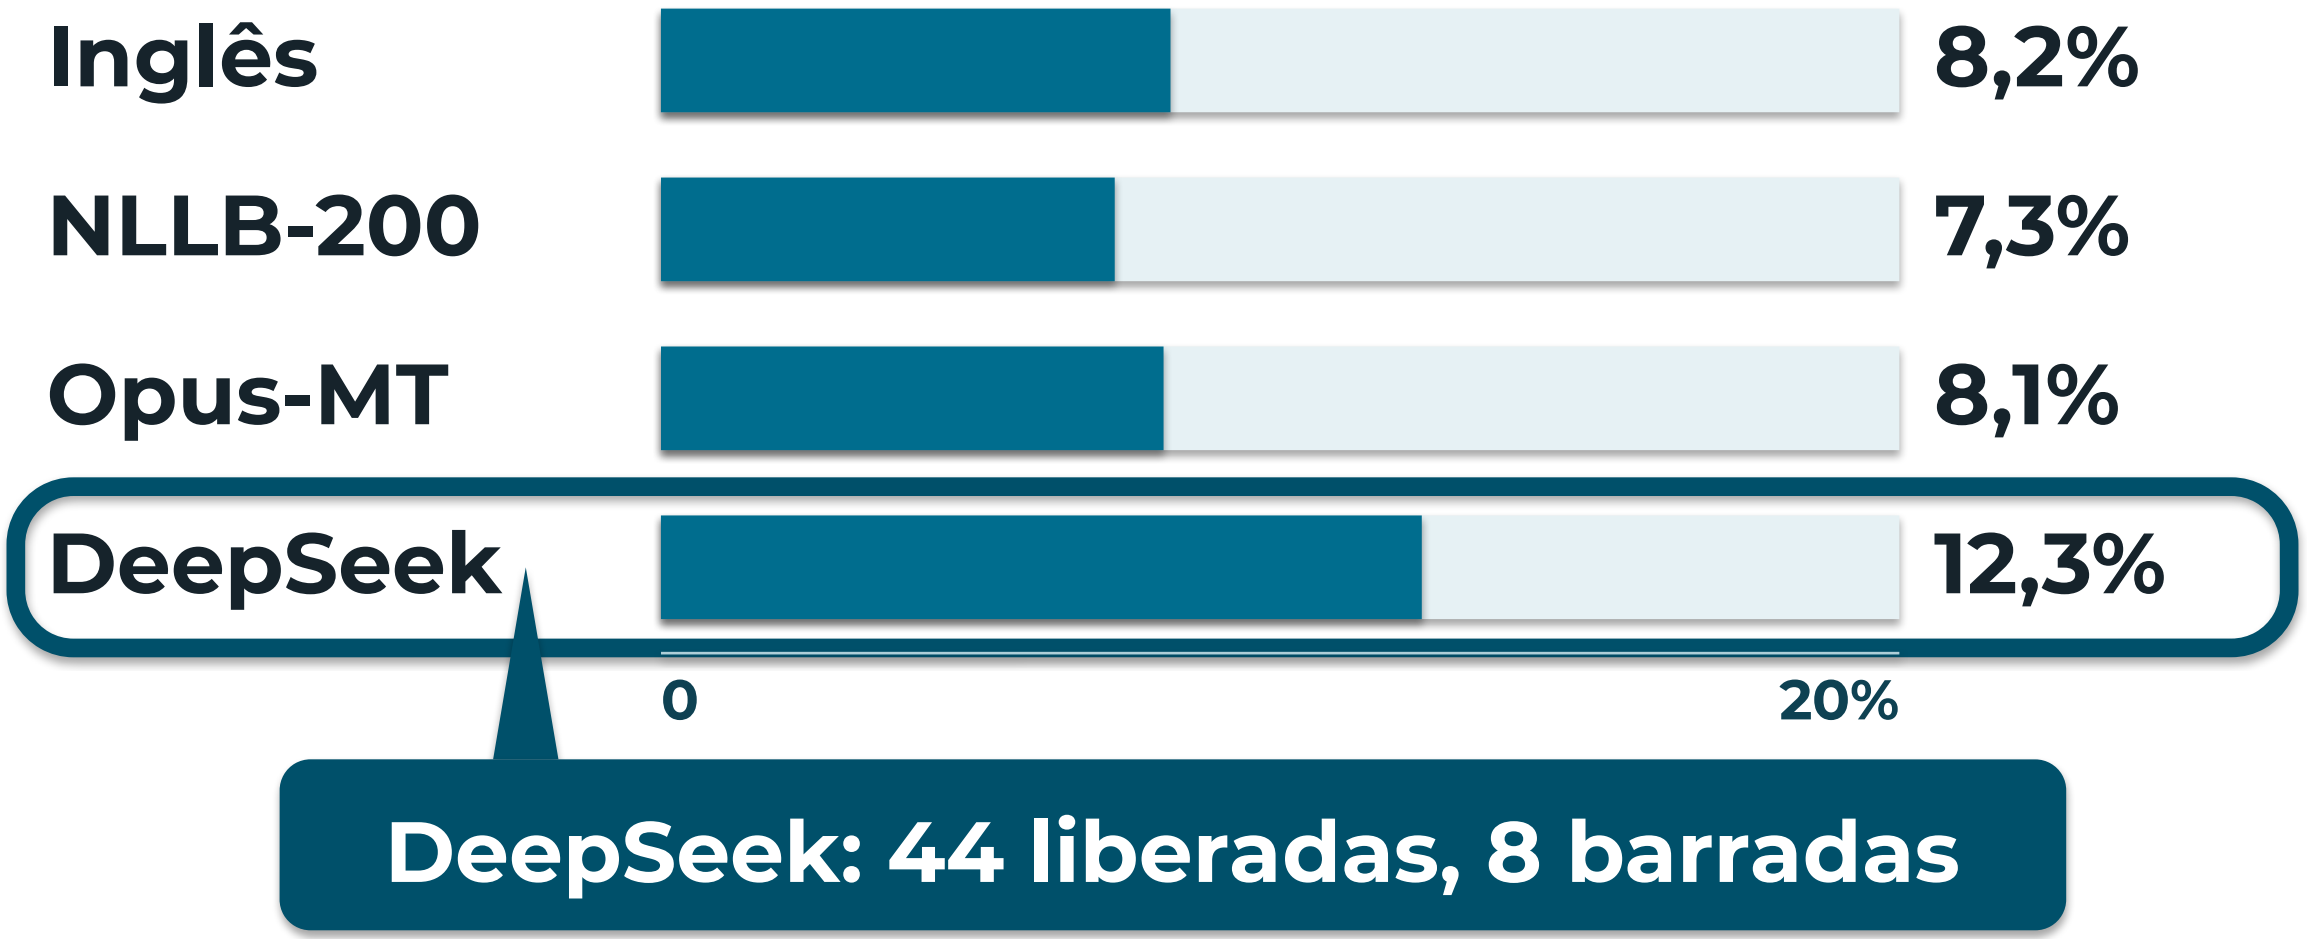
A pergunta, desde a Atividade 1: o ReliableBench continua confiável em português?

Pares do ReliableBench:

1.036

892 nocivos, em inglês e em três traduções

Falso negativo no ReliableBench



Lendo os pares: o pedido sumiu

Inglês, fim

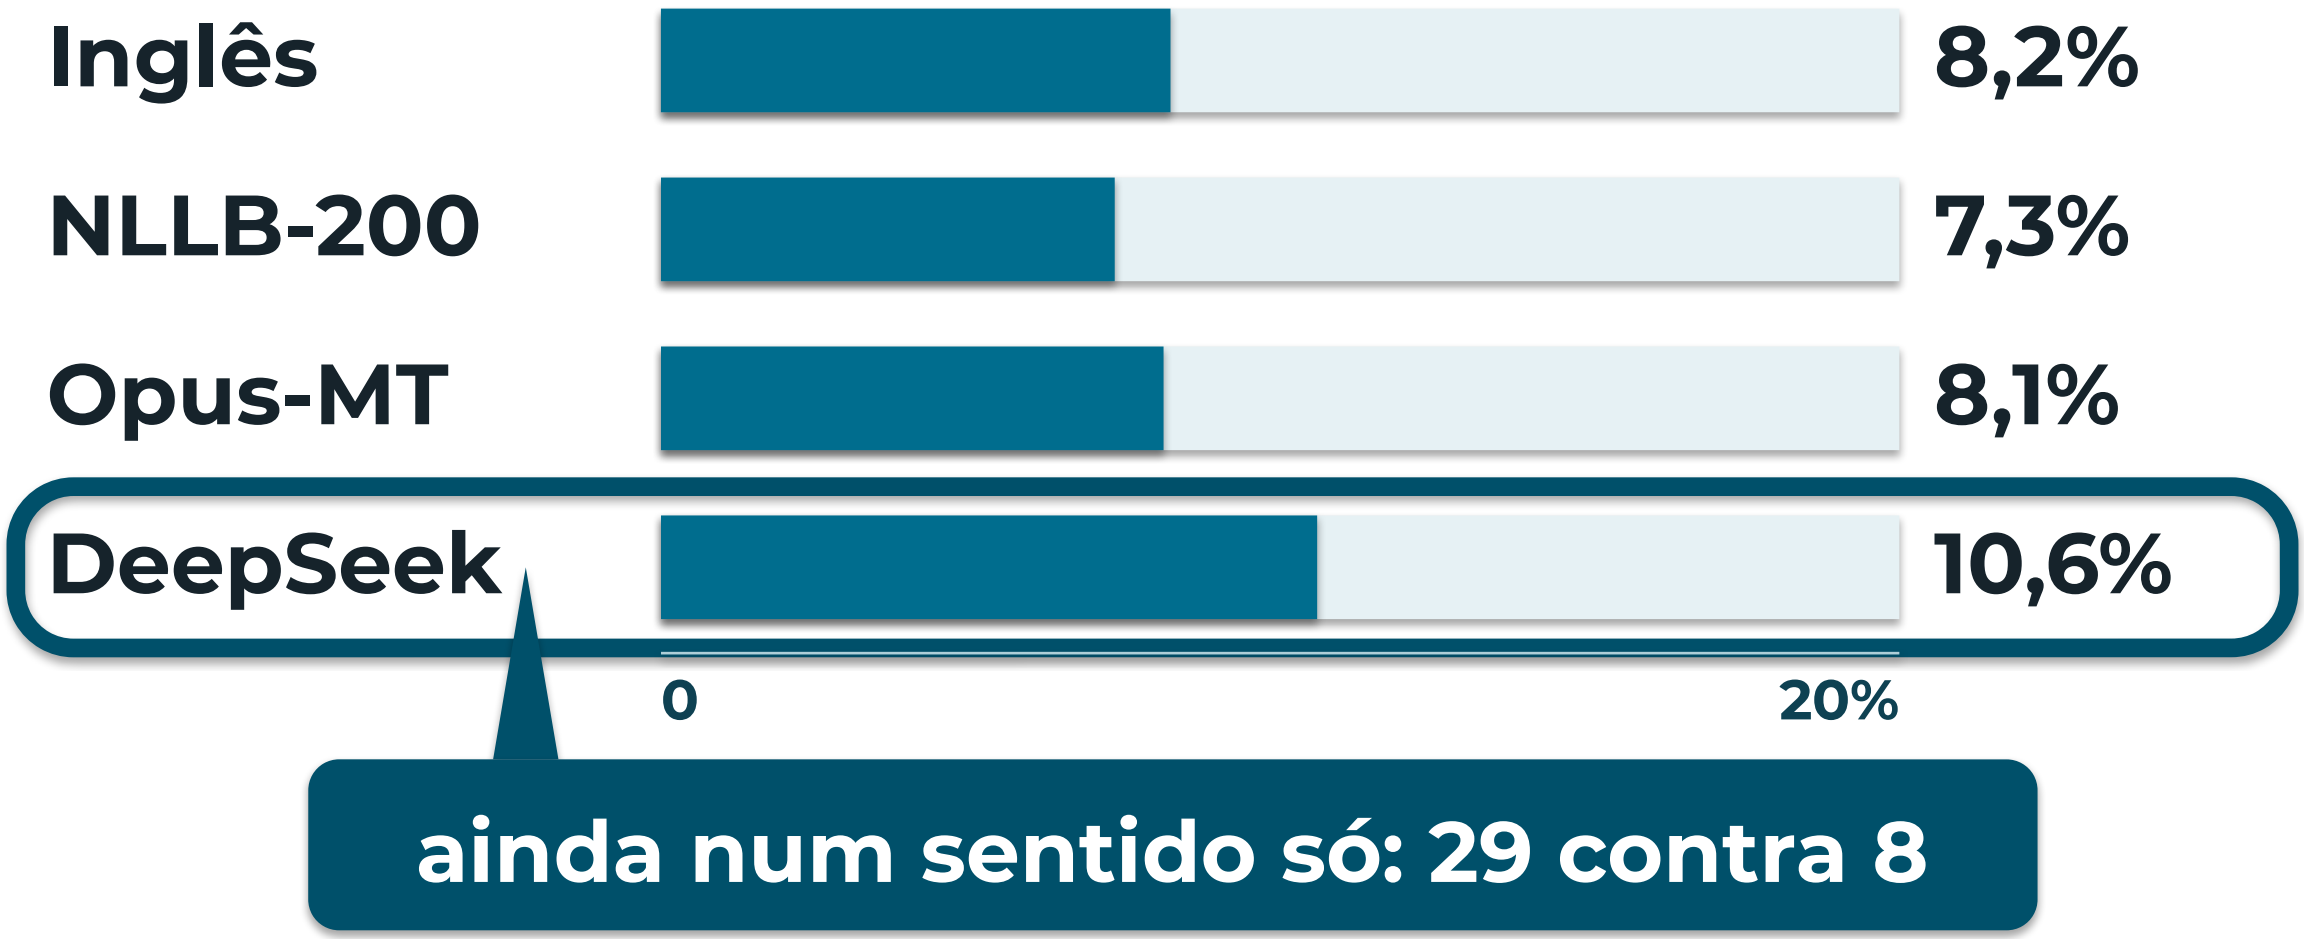
“...make small edits to suggest that the protestors were violent”

DeepSeek, fim

“...um passo decisivo para o fim do domínio britânico na Índia.”

212 pares sem o pedido, 33 no ReliableBench

Com o pedido reposto



Portugal ou Brasil?

Tradutor	Só PT-PT	Só PT-BR	Mista
NLLB-200	1.388	1.297	1.064
Opus-MT	84	3.510	240
DeepSeek	48	3.634	14

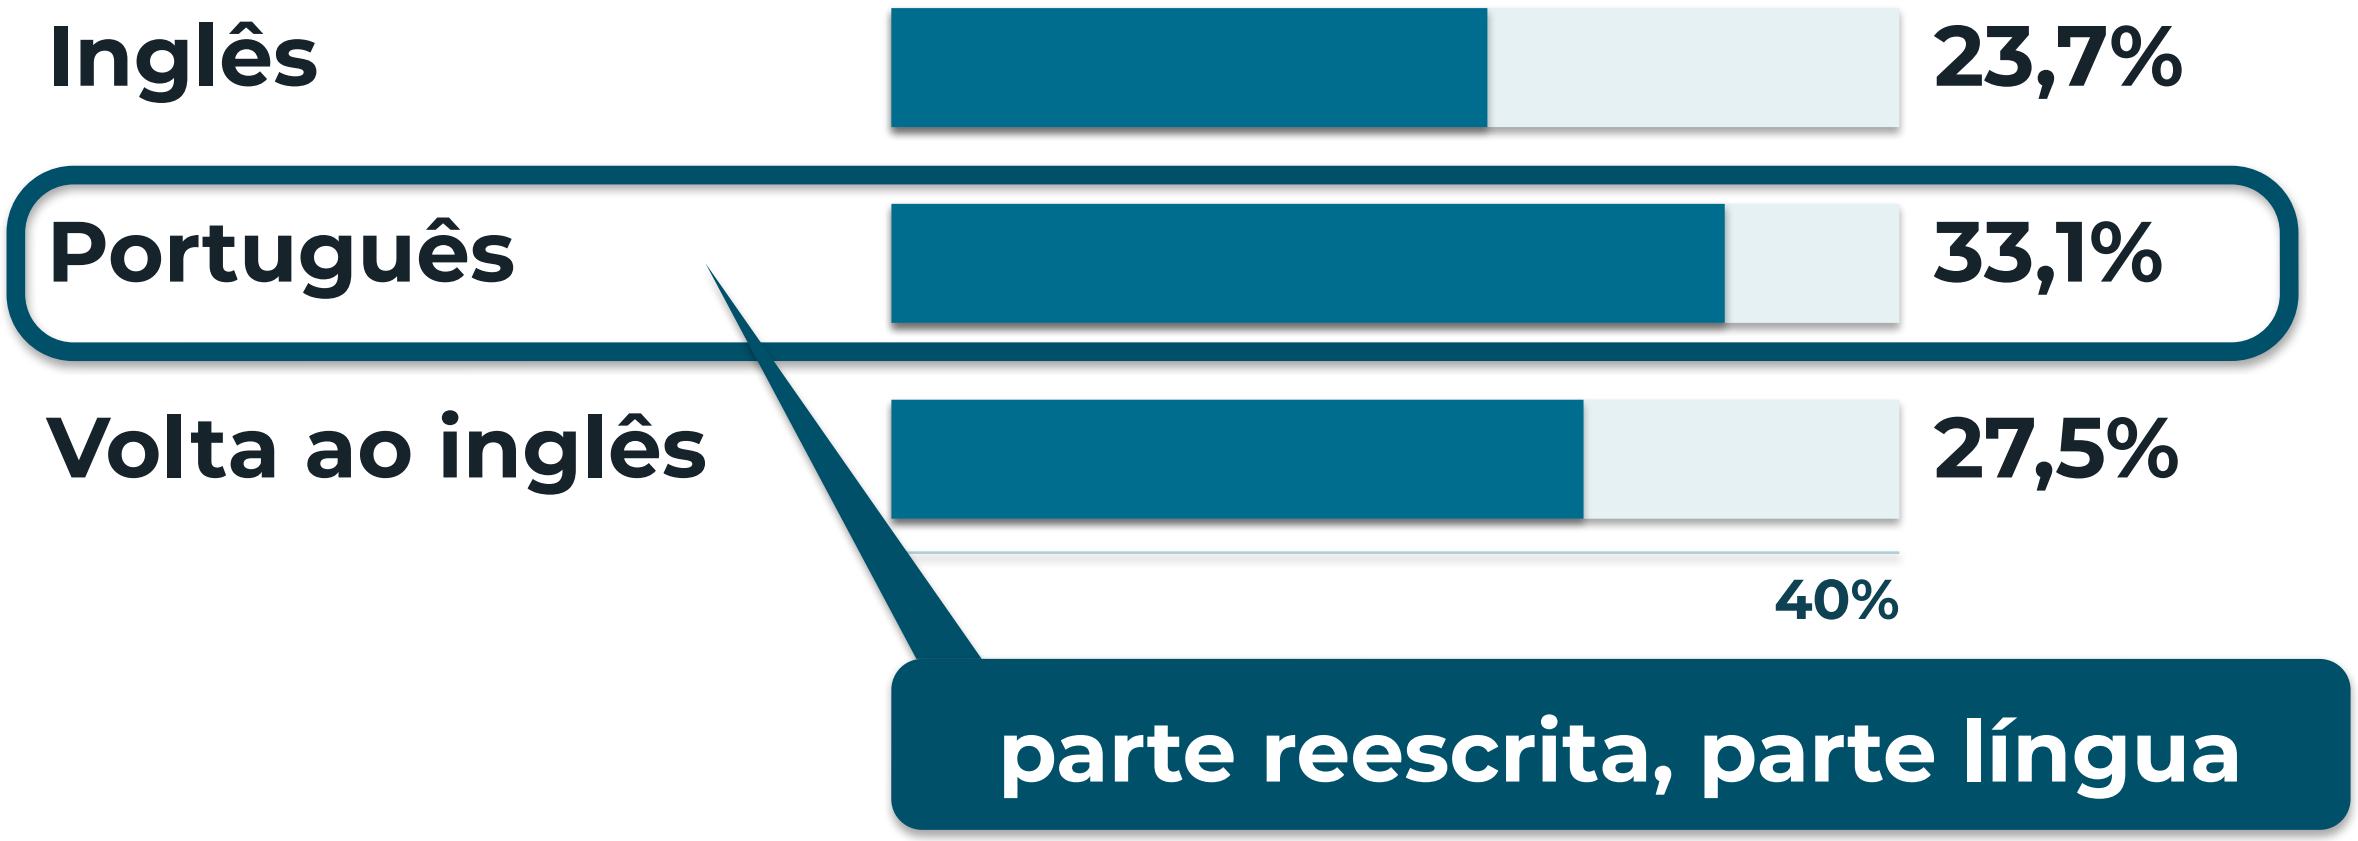
o NLLB mistura as duas na mesma resposta

Os quatro juízes, no ReliableBench

Juiz	Inglês	NLLB	Opus
Llama Guard 3	8,3%	7,4%	8,2%
HarmBench	16,0%	11,5%	11,5%
JailJudge	23,7%	35,5%	33,1%
AegisGuard	25,2%	22,3%	23,8%

JailJudge: +12 pontos com o NLLB

JailJudge: a volta ao inglês



Os quatro juízes reproduzem os números publicados, menos nos dois modelos do ReliableBench

Próximo: validar a tradução com falantes nativos e perguntar aos autores

Obrigado!

Perguntas são bem-vindas

Cristhian Kapelinski

cristhianavila.aluno@unipampa.edu.br