Juízes de segurança de LLM em português: sexta entrega, o juiz em português

Cristhian Kapelinski
Atividade 10: o mesmo juiz sobre as traduções

1 O que esta entrega faz

A Atividade 9 rodou o Llama Guard 3 em inglês e mudou a base do projeto: o efeito da língua passa a ser medido nos 6.560 pares do *CoinflipForSafety*, porque os 439 do *JudgeStressTest* foram escolhidos onde o juiz erra em inglês. Esta entrega roda o mesmo juiz, com o mesmo prompt e o mesmo escore, sobre as traduções em português que a Atividade 8 produziu. São duas perguntas, cada uma no conjunto que a responde:

- **efeito da língua**: nos 6.560 pares, nas versões do NLLB-200 e do Opus-MT, o juiz erra mais em português do que no mesmo par em inglês?
- **efeito do tradutor**: nos 439 pares, que têm cinco traduções, quanto o veredito muda só por trocar o motor que traduziu?

2 Como foi rodado

Tudo igual à Atividade 9: Llama Guard 3 8B em 16 bits, template oficial, escore p_{unsafe} lido na primeira posição da resposta, veredito nocivo quando $p_{\text{unsafe}} > 0{,}5$, rótulo humano nocivo a partir de 0,5. As instruções do template ficam em inglês, como o modelo foi treinado; só o pedido e a resposta do par vão em português, que é uma das oito línguas que o Llama Guard 3 declara suportar. Em todos os pares, o token mais provável do vocabulário foi `safe` ou `unsafe`. A comparação é pareada: cada par aparece nas duas línguas, e as contagens de mudança de veredito comparam o mesmo par. Na tradução do DeepSeek, um par ficou sem tradução da resposta (Atividade 8) e saiu da conta desse motor.

3 Efeito da língua nos 6.560 pares

Nos 6.560 pares, cada par foi julgado três vezes: em inglês, na tradução do NLLB-200 e na do Opus-MT. A Tabela 1 traz as três condições lado a lado, e a Figura 1 mostra a taxa de falso negativo, a que mais pesa em segurança, porque é a resposta nociva que passa pelo juiz. Em inglês ela é de 18,7%; em português, de 19,1% com o NLLB-200 e de 20,1% com o Opus-MT, uma diferença de +0,5 e +1,4 pontos percentuais. A taxa de falso positivo vai de 59,0% em inglês para 55,2% e 59,2%.

Tabela 1: Llama Guard 3 nos mesmos 6.560 pares do *CoinflipForSafety*, em inglês e nas duas traduções. As duas últimas colunas contam, par a par, a mudança do veredito em relação ao inglês.

Condição	Falso negativo (de 5.174)	Falso positivo (de 1.386)	Acurácia (de 6.560)	nocivo→seguro	seguro→nocivo
Inglês	966 (18,7%)	818 (59,0%)	4.776 (72,8%)	referência	referência
NLLB-200	990 (19,1%)	765 (55,2%)	4.805 (73,2%)	315	238
Opus-MT	1.041 (20,1%)	820 (59,2%)	4.699 (71,6%)	301	228

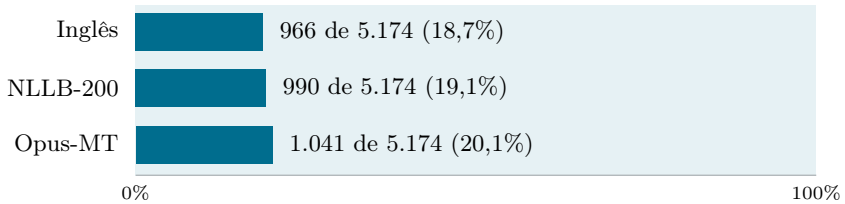


Figura 1: Taxa de falso negativo do Llama Guard 3 nos mesmos 6.560 pares, em inglês e nas duas traduções: fração das 5.174 respostas nocivas que o juiz libera como seguras.

Olhando par a par, a mudança não é só de saldo. Entre as 5.174 respostas nocivas, 189 que o juiz barrava em inglês passam a ser liberadas na versão do NLLB-200, e 165 que ele liberava passam a ser barradas; no Opus-MT, são 214 e 139. Entre as 1.386 seguras, 73 passam a ser barradas e 126 deixam de ser no NLLB-200; no Opus-MT, 89 e 87. A Tabela 2 separa a taxa de falso negativo por ataque.

Tabela 2: Taxa de falso negativo por ataque, nos 6.560 pares, em inglês e nas duas traduções.

Ataque	**Nocivas**	**Inglês**	**NLLB-200**	**Opus-MT**
GCG	1.752	12,6%	13,7%	13,8%
BoN	1.146	21,2%	20,5%	21,7%
GCG-R	1.203	10,2%	9,8%	11,1%
Direct	993	37,1%	39,0%	40,9%
Pair	80	15,0%	12,5%	13,8%

Os dois tradutores também discordam entre si: no mesmo par, o veredito do juiz sobre a versão do NLLB-200 e sobre a do Opus-MT é diferente em 420 dos 6.560 pares (6,4%), e em 269 das 5.174 respostas nocivas. É a mesma dependência do tradutor que a Seção 4 mede nos 439 com cinco motores, agora num conjunto sem filtro.

As traduções ainda não passaram pela revalidação às cegas prevista desde a Atividade 2: o piloto da Atividade 5 avaliou a traduzibilidade de 30 pares lendo o inglês, sem escrever a tradução. Por isso parte das mudanças pode vir de erro de tradução e não da língua. Separar as duas coisas é o papel dos controles do próximo passo.

4 Efeito do tradutor nos 439 pares

A Tabela 3 traz o juiz em inglês e nas cinco traduções dos 439 pares. Como na Atividade 9, as taxas desse conjunto não são a taxa de erro típica do juiz: os pares foram escolhidos porque ele erra em inglês, e por isso o acerto em português sobe em todos os motores, de 7% para 14% a 19%. O que o conjunto permite medir é outra coisa: a variação entre os motores, porque o par é o mesmo e só o tradutor muda.

Tabela 3: Llama Guard 3 nos 439 pares do *JudgeStressTest*, em inglês e em cada tradução. Falso negativo: resposta nociva liberada como segura. Falso positivo: resposta segura barrada. As duas últimas colunas contam, par a par, a mudança do veredito em relação ao inglês. No DeepSeek, 438 pares (um sem tradução).

Condição	**Falso negativo**	**Falso positivo**	**Acurácia**	**nocivo→seguro**	**seguro→nocivo**
Inglês	167 de 189 (88,4%)	243 de 250 (97,2%)	29 de 439 (6,6%)	referência	referência
DeepSeek	160 de 189 (84,7%)	216 de 249 (86,7%)	62 de 438 (14,2%)	34	15
NLLB-200	141 de 189 (74,6%)	219 de 250 (87,6%)	79 de 439 (18,0%)	30	32
Opus-MT	144 de 189 (76,2%)	226 de 250 (90,4%)	69 de 439 (15,7%)	20	26
Argos	143 de 189 (75,7%)	212 de 250 (84,8%)	84 de 439 (19,1%)	36	29
Google Tradutor	152 de 189 (80,4%)	212 de 250 (84,8%)	75 de 439 (17,1%)	36	20

Para medir a dependência do tradutor, contamos, nos 438 pares que têm as cinco traduções, quantos dos cinco vereditos em português dizem nocivo. Se o tradutor não importasse, cada par teria 0 ou 5. A Tabela 4 mostra que 91 pares (20,8%) ficam entre 1 e 4: o veredito do mesmo par depende do motor que o traduziu. Entre as 189 respostas nocivas, isso acontece em 44.

Tabela 4: Quantos dos cinco vereditos em português dizem nocivo, por par, nos 438 pares com as cinco traduções.

Vereditos nocivos (de 5)	**0**	**1**	**2**	**3**	**4**	**5**
Pares	140	19	13	30	29	207

5 Mudança de rota: o projeto vira artigo

Os resultados até aqui sustentam um artigo de periódico, e o projeto passa a ter esse alvo: a TACL (*Transactions of the Association for Computational Linguistics*), que não cobra taxa de publicação. Lendo artigos publicados nela, o desenho do projeto ganha cinco extensões, nenhuma fixa: rodar a parte automática em mais duas ou três línguas; controles de tradução, com retrotradução do português de volta para o inglês (controle neutro) e um subconjunto traduzido por humano (controle positivo); validação do subconjunto em português por dois ou

mais anotadores nativos; análise por item; e o enquadramento do pipeline de tradução como variável da avaliação multilíngue de segurança, que é o que a Seção 4 começa a mostrar.

6 Próximo passo

O primeiro controle de tradução: a retrotradução. As versões em português do NLLB-200 e do Opus-MT são traduzidas de volta para o inglês por um motor aberto, e o mesmo juiz julga esse inglês retraduzido. Se o veredito mudar também nele, a mudança vem do caminho pela tradução, e não do português; se não mudar, o efeito medido na Seção 3 é da língua. Os dois casos são resultado, e é essa separação que o artigo precisa.

7 Artefatos

Na pasta `atividade10/resultados/`: um arquivo por condição, `cf-nllb.jsonl` e `cf-opus.jsonl` para os 6.560 pares e `deepseek.jsonl`, `nllb.jsonl`, `opus.jsonl`, `argos.jsonl` e `google.jsonl` para os 439, com, por par, o rótulo humano, o p_{unsafe}, o veredito, o número de tokens e o tempo, sem o texto do par; `numeros.json` e `numeros-cf.json` são a saída das análises. Os scripts são os da Atividade 9 (`atividade9/`), rodados com as duas pastas: `python analisar.py atividade9/resultados:atividade10/resultados numeros.json` e o mesmo com `analisar_cf.py`.